

# Práctica PADRON

## Práctica Hive + Impala + HDFS + Spark

- A partir de los datos (CSV) de Padrón de Madrid (<https://datos.madrid.es/egob/catalogo/200076-1-padron.csv>) llevar a cabo lo siguiente:

### 1- Creación de tablas en formato texto.

- 1.1) Crear Base de datos "datos\_padron" .

```
hive> CREATE DATABASE datos_padron
> ;
OK
Time taken: 1.627 seconds
```

- 1.2) Crear la tabla de datos padron\_txt con todos los campos del fichero CSV y cargar los datos mediante el comando LOAD DATA LOCAL INPATH. La tabla tendrá formato texto y tendrá como delimitador de campo el caracter ';' y los campos que en el documento original están encerrados en comillas dobles "" no deben estar envueltos en estos caracteres en la tabla de Hive (es importante indicar esto utilizando el serde de OpenCSV, si no la importación de las variables que hemos indicado como numéricas fracasará ya que al estar envueltos en comillas los toma como strings) y se deberá omitir la cabecera del fichero de datos al crear la tabla.

Creación de la tabla con los parámetros que nos dicen

```
hive> CREATE TABLE padron_txt (
>   COD_DISTrito INT,
>   DESC_DISTrito STRING,
>   COD_DIST_BARRIO INT,
>   DESC_BARRIO STRING,
>   COD_BARRIO INT,
>   COD_DIST_SECCION INT,
>   COD_SECCION INT,
>   COD_EDAD INT,
>   ESPANOLESHOMBRES INT,
>   ESPANOLESMUJERES INT,
>   EXTRANJEROSHOMBRES INT,
>   EXTRANJEROSMUJERES INT,
>   FX_CARGA TIMESTAMP,
>   FX_DATOS_INI DATE,
>   FX_DATOS_FIN DATE
> )
> ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
> WITH SERDEPROPERTIES (
>   "separatorChar" = ";",
>   "quoteChar" = "\"",
>   "escapeChar" = "\\"
> )
> STORED AS TEXTFILE
> TBLPROPERTIES ("skip.header.line.count"="1");
OK
Time taken: 0.058 seconds
```

Cargamos los datos desde el csv a la tabla

```
hive> LOAD DATA LOCAL INPATH '/home/cloudera/Desktop/padron.csv' INTO TABLE padron_txt;
Loading data to table datos_padron.padron_txt
Table datos_padron.padron_txt stats: [numFiles=1, totalSize=34057160]
OK
Time taken: 0.485 seconds
```

• **1.3) Hacer trim sobre los datos para eliminar los espacios innecesarios guardando la tabla resultado como padron\_txt\_2. (Este apartado se puede hacer creando la tabla con una sentencia CTAS.)**

Create Table As Select (CTAS)

```
hive> CREATE TABLE padron_txt_2 AS
> SELECT
>     COD_DISTrito,
>     TRIM(DESC_DISTrito) AS DESC_DISTrito,
>     COD_DIST_BARRIO,
>     TRIM(DESC_BARRIO) AS DESC_BARRIO,
>     COD_BARRIO,
>     COD_DIST_SECCION,
>     COD_SECCION,
>     COD_EDAD_INT,
>     ESPANOLESHOMBRES,
>     ESPANOLESMUJERES,
>     EXTRANJEROSHOMBRES,
>     EXTRANJEROSMUJERES,
>     FX_CARGA,
>     FX_DATOS_INI,
>     FX_DATOS_FIN
> FROM padron_txt;
Query ID = cloudera_20240730115757_fd3ba867-d836-45eb-9e32-43d03be635f4
Total jobs = 3

Stage-Stage-1: Map: 1   Cumulative CPU: 4.31 sec   HDFS Read: 34062895 HDFS Write: 26422298 SUCCESS
Total MapReduce CPU Time Spent: 4 seconds 310 msec
OK
cod_distrito  desc_distrito  cod_dist_barrio  desc_barrio      cod_barrio      cod_dist_seccion  c
rga      fx_datos_ini  fx_datos_fin
Time taken: 19.981 seconds
```

• **1.4) Investigar y entender la diferencia de incluir la palabra LOCAL en el comando LOAD DATA.**

La palabra clave **LOCAL** en el comando **LOAD DATA** en Hive tiene una importancia significativa en cuanto a la ubicación de los datos que estás cargando en la tabla de Hive.

- El comando **LOAD DATA** en Hive se utiliza para mover datos desde un archivo en el sistema de archivos al directorio de la tabla en el sistema de archivos de Hadoop (HDFS).

```
LOAD DATA [LOCAL] INPATH 'path' [OVERWRITE] INTO TABLE table_name;
```

- Cuando usas **LOAD DATA** sin la palabra clave **LOCAL**, Hive asume que el archivo o directorio especificado está ubicado en el sistema de archivos distribuido de Hadoop (HDFS). En este caso, el archivo debe estar en HDFS, no en el sistema de archivos local del nodo donde se ejecuta Hive.

```
LOAD DATA INPATH '/user/hive/warehouse/data.csv' INTO TABLE padron_txt;
```

- ```
hive> SELECT
>   COUNT(*) AS total_rows,
>   COUNT(CASE WHEN TRIM(ESPAÑOLES_HOMBRES) = '' THEN 1 END) AS empty_esp_hombres,
>   COUNT(CASE WHEN TRIM(ESPAÑOLES_MUJERES) = '' THEN 1 END) AS empty_esp_mujeres,
>   COUNT(CASE WHEN TRIM(EXTRANJEROS_HOMBRES) = '' THEN 1 END) AS empty_extranjero_hombres,
>   COUNT(CASE WHEN TRIM(EXTRANJEROS_MUJERES) = '' THEN 1 END) AS empty_extranjero_mujeres
> FROM padron_txt;
```
- | total_rows | empty_esp_hombres | empty_esp_mujeres | empty_extranjero_hombres | empty_extranjero_mujeres |
|------------|-------------------|-------------------|--------------------------|--------------------------|
| 239342     | 0                 | 0                 | 0                        | 0                        |
- Time taken: 26.265 seconds, Fetched: 1 row(s)

- 1.6) Una manera tremendamente potente de solucionar todos los problemas previos (tanto las comillas como los campos vacíos que no son catalogados como null y los espacios innecesarios) es utilizar expresiones regulares (regex) que nos proporciona OpenCSV.

```
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.RegexSerDe'
WITH SERDEPROPERTIES ('input.regex'='XXXXXXX')
```

```
hive> CREATE TABLE padron_txt_2 (  
    > COD_DISTrito INT,  
    > DESC_DISTrito STRING,  
    > COD_DIST_BARRIO INT,  
    > DESC_BARRIO STRING,  
    > COD_BARRIO INT,  
    > COD_DIST_SECCION INT,  
    > COD_SECCION INT,  
    > COD_EDAD INT STRING,  
    > ESPANOLESHOMBRES INT,  
    > ESPANOLESMUJERES INT,  
    > EXTRANJEROSHOMBRES INT,  
    > EXTRANJEROSMUJERES INT,  
    > FX_CARGA TIMESTAMP,  
    > FX_DATOS_INI DATE,  
    > FX_DATOS_FIN DATE  
    > )  
    > ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.RegexSerDe'  
    > WITH SERDEPROPERTIES (  
        > "input.regex" = "(^\\d+\\.?)$|^\"([^\"]*)\"\\\\|(^\\d+)\\.?|^\"([^\"]*)\"\\\\|(^\\d+)\\.?|^\"([^\"]*)\"\\\\|(^\\d+)\\.?|^\"([^\"]*)\"\\\\|(^[^\"\\\\\\\\]+)\\\\|$"  
        > )  
    > STORED AS TEXTFILE;
```

La inserción de datos, los metemos omitiendo el header, par que no de NULL los campos del header, y luego lo volvemos a añadir los campos manual:

```
hive> LOAD DATA LOCAL INPATH '/home/cloudera/Desktop/padron.csv' INTO TABLE padron_txt_2;
Loading data to table default.padron_txt_2
Table default.padron_txt_2 stats: [numFiles=1, totalSize=34056941]
OK
Time taken: 0.475 seconds
```

| padron_txt_2.cod_distrito | padron_txt_2.desc_distrito | padron_txt_2.cod_dist_barrio | padron_txt_2.desc_barrio | padron_txt_2.cod_barrio | padron_txt_2.cod_seccion | padron_txt_2.desc_seccion | padron_txt_2.espanoleshombres | padron_txt_2.espanolesmujer | padron_txt_2.extranjeroshombres | padron_txt_2.extranjerosmujer | padron_txt_2.fx_carga | padron_txt_2.fx_datos_ini | padron_txt_2.fx_datos_fin |
|---------------------------|----------------------------|------------------------------|--------------------------|-------------------------|--------------------------|---------------------------|-------------------------------|-----------------------------|---------------------------------|-------------------------------|-----------------------|---------------------------|---------------------------|
| 2                         | ARGANZUELA                 | 202                          | ACACIAS                  | 2                       | 2094                     | 94                        | 47                            | 6                           | 16                              | 0                             | 0                     | 2024-07-07 00:00:01       |                           |
| .8166596                  | 2024-07-01                 | 2024-07-01                   |                          |                         |                          |                           |                               |                             |                                 |                               |                       |                           |                           |
| 18                        | VILLA DE VALLECAS          | 1802                         | SANTA EUGENIA            | 2                       | 18029                    | 29                        | 77                            | 7                           | 3                               | 0                             | 2                     | 2024-07-07 00:00:01       |                           |
| .8166596                  | 2024-07-01                 | 2024-07-01                   |                          |                         |                          |                           |                               |                             |                                 |                               |                       |                           |                           |
| 2                         | ARGANZUELA                 | 205                          | DELICIAS                 | 5                       | 2062                     | 62                        | 71                            | 6                           | 6                               | 0                             | 2                     | 2024-07-07 00:00:01       |                           |
| .8166596                  | 2024-07-01                 | 2024-07-01                   |                          |                         |                          |                           |                               |                             |                                 |                               |                       |                           |                           |
| 9                         | MONCLOA-ARAVACA            | 907                          | ARAVACA                  | 7                       | 9083                     | 83                        | 55                            | 15                          | 14                              | 0                             | 0                     | 2024-07-07 00:00:01       |                           |
| .8166596                  | 2024-07-01                 | 2024-07-01                   |                          |                         |                          |                           |                               |                             |                                 |                               |                       |                           |                           |
| 3                         | RETIRO                     | 306                          | NIÑO JESUS               | 6                       | 3080                     | 80                        | 60                            | 7                           | 8                               | 1                             | 1                     | 2024-07-07 00:00:01       |                           |
| .8166596                  | 2024-07-01                 | 2024-07-01                   |                          |                         |                          |                           |                               |                             |                                 |                               |                       |                           |                           |

Time taken: 0.066 seconds, Fetched: 5 row(s)

Una vez finalizados todos estos apartados deberíamos tener una tabla **padron\_txt** que conserve los espacios innecesarios, no tenga comillas envolviendo los campos y los campos nulos sean tratados como valor 0 y otra tabla **padron\_txt\_2** y **padron2** sin espacios innecesarios, sin comillas envolviendo los campos y con los campos nulos como valor 0. Idealmente esta tabla ha sido creada con las regex de OpenCSV.

A priori y por lo que he comprobado, lo tengo listo para trabajar

## 2- Investigamos el formato columnar parquet.

### • 2.1) ¿Qué es CTAS?

CTAS significa "Create Table As Select" y es una técnica en SQL (y otras bases de datos) utilizada para crear una nueva tabla basada en los resultados de una consulta SELECT. Este método es muy útil para copiar datos de una tabla a otra o para crear una nueva tabla con una estructura y datos específicos sin tener que definir manualmente cada columna y tipo de datos.

### • 2.2) Crear tabla Hive **padron\_parquet** (cuyos datos serán almacenados en el formato columnar parquet) a través de la tabla **padron\_txt** mediante un CTAS.

```
hive> CREATE TABLE padron_parquet
>   STORED AS PARQUET
>   AS
>   SELECT
>     COD_DISTrito,
>     DESC_DISTrito,
>     COD_DIST_BARRIO,
>     DESC_BARRIO,
>     COD_BARRIO,
>     COD_DIST_SECCION,
>     COD_SECCION,
>     COD_EDAD_INT,
>     ESPANOLESHOMBRES,
>     ESPANOLESMUJERES,
>     EXTRANJEROSHOMBRES,
>     EXTRANJEROSMUJERES,
>     FX_CARGA,
>     FX_DATOS_INI,
>     FX_DATOS_FIN
>   FROM padron_txt;
Query ID = cloudera_20240731091414_728a4d71-9bdf-4efa-9361-59e51971002b
Total jobs = 3
```

Comprobamos que la creación ha ido bien:

```
hive> select * from padron_parquet limit 3;
OK
padron_parquet.cod_distrito    padron_parquet.desc_distrito    padron_parquet.cod_dist_barrio    padron_parquet.desc_barrio    padron_parquet.cod_barrio p
adron_parquet.cod_dist_seccion    padron_parquet.cod_seccion    padron_parquet.cod_edad_int    padron_parquet.espanolshombres    padron_parquet.espanolsmuj
et.fx_datos_fin
NULL    DESC_DISTRITO    NULL    DESC_BARRIO    NULL    NULL    NULL    COD_EDAD_INT    NULL    NULL    NULL    NULL    NULL    FX_DATOS_INI    FX_DATOS_FI
N
2    "ARGANZUELA"    "    202    "ACACIAS"    "    2    2094    94    "    47"    6    16    0    0    NULL    "2024-07-01
"    "2024-07-01"
18    "VILLA DE VALLECAS"    "    1802    "SANTA EUGENIA"    "    2    18029    29    "    77"    7    3    0    2    NULL    "2024-07-01
"    "2024-07-01"
Time taken: 0.039 seconds, Fetched: 3 row(s)
```

• **2.3) Crear tabla Hive padron\_parquet\_2 a través de la tabla padron\_txt\_2 mediante un CTAS. En este punto deberíamos tener 4 tablas, 2 en txt (padron\_txt y padron\_txt\_2, la primera con espacios innecesarios y la segunda sin espacios innecesarios) y otras dos tablas en formato parquet (padron\_parquet y padron\_parquet\_2, la primera con espacios y la segunda sin ellos).**

Parquet en Hive no soporta "date", por lo que hay que hacer algún cambio:

En vez de date, lo metemos como timestamp el dato.

```
hive> CREATE TABLE padron_parquet_2 (
>   COD_DISTRITO INT,
>   DESC_DISTRITO STRING,
>   COD_DIST_BARRIO INT,
>   DESC_BARRIO STRING,
>   COD_BARRIO INT,
>   COD_DIST_SECCION INT,
>   COD_SECCION INT,
>   COD_EDAD_INT INT,
>   ESPANOLES_HOMBRES INT,
>   ESPANOLES_MUJERES INT,
>   EXTRANJEROS_HOMBRES INT,
>   EXTRANJEROS_MUJERES INT,
>   FX_CARGA TIMESTAMP,
>   FX_DATOS_INI STRING,
>   FX_DATOS_FIN STRING
> )
> STORED AS PARQUET;
OK
Time taken: 0.087 seconds
hive>
> INSERT INTO padron_parquet_2
> SELECT
>   COD_DISTRITO,
>   TRIM(DESC_DISTRITO) AS DESC_DISTRITO,
>   COD_DIST_BARRIO,
>   TRIM(DESC_BARRIO) AS DESC_BARRIO,
>   COD_BARRIO,
>   COD_DIST_SECCION,
>   COD_SECCION,
>   CASE WHEN TRIM(COD_EDAD_INT) = '' THEN 0 ELSE CAST(TRIM(COD_EDAD_INT) AS INT) END AS COD_EDAD_INT,
>   ESPANOLES_HOMBRES,
>   ESPANOLES_MUJERES,
>   EXTRANJEROS_HOMBRES,
>   EXTRANJEROS_MUJERES,
>   FX_CARGA,
>   FX_DATOS_INI,
>   FX_DATOS_FIN
> FROM padron_txt_2;
```

Comprobamos que ha ido bien la creación:

```
hive> select * from padron_parquet_2 limit 3;
OK
padron_parquet_2.cod_distrito    padron_parquet_2.desc_distrito    padron_parquet_2.cod_dist_barrio    padron_parquet_2.desc_barrio    padron_parquet_2.co
d_barrio    padron_parquet_2.cod_dist_seccion    padron_parquet_2.cod_seccion    padron_parquet_2.cod_edad_int    padron_parquet_2.espanolshombres p
adron_parquet_2.espanolsmujeres    padron_parquet_2.extranjeros_hombres    padron_parquet_2.extranjeros_mujeres    padron_parquet_2.fx_carga    pad
ron_parquet_2.fx_datos_ini    padron_parquet_2.fx_datos_fin
2    ARGANZUELA    202    ACACIAS    2    2094    94    47    6    16    0    0    2024-07-07 00:00:01.8166596    2024-07-01    202
4-07-01
18    VILLA DE VALLECAS    1802    SANTA EUGENIA    2    18029    29    77    7    3    0    2    2024-07-07 00:00:01.8166596    202
4-07-01 2024-07-01
2    ARGANZUELA    205    DELICIAS    5    2062    62    71    6    6    0    2    2024-07-07 00:00:01.8166596    2024-07-012
024-07-01
Time taken: 0.074 seconds, Fetched: 3 row(s)
```

**2.4) Opcionalmente también se pueden crear las tablas directamente desde 0 (en lugar de mediante CTAS) en formato parquet igual que lo hicimos para el formato txt incluyendo la sentencia STORED AS PARQUET. Es importante para comparaciones posteriores que la tabla padron\_parquet conserve los espacios innecesarios y la tabla padron\_parquet\_2 no los tenga. Dejo a tu elección cómo hacerlo.**

La tabla "mala"

```
hive> CREATE TABLE padron_parquet (
  >   COD_DISTrito STRING,
  >   DESC_DISTrito STRING,
  >   COD_DIST_BARRIO STRING,
  >   DESC_BARRIO STRING,
  >   COD_BARRIO STRING,
  >   COD_DIST_SECCION STRING,
  >   COD_SECCION STRING,
  >   COD_EDAD_INT STRING,
  >   ESPANOLESHOMBRES STRING,
  >   ESPANOLESMUJERES STRING,
  >   EXTRANJEROSHOMBRES STRING,
  >   EXTRANJEROSMUJERES STRING,
  >   FX_CARGA STRING,
  >   FX_DATOS_INI STRING,
  >   FX_DATOS_FIN STRING
  > )
  > STORED AS PARQUET;
OK
Time taken: 0.085 seconds

hive> INSERT INTO padron_parquet SELECT * FROM padron_txt;
```

Comprobación:

```
hive> select * from padron_parquet limit 3;
OK
padron_parquet.cod_distrito padron_parquet.desc_distrito padron_parquet.cod_dist_barrio padron_parquet.desc_barrio padron_parquet.cod_barrio padron_parquet.cod_dist_seccion padron_parquet.cod_sec
t.cod_edad_int padron_parquet.espanolshombres padron_parquet.espanolesmujeres padron_parquet.extranjeroshombres padron_parquet.extranjerosmujeres padron_parquet.fx_carga padron_parquet.fx_datos_ini
os fin
NULL DESC_DISTrito NULL DESC_BARRIO NULL NULL NULL COD_EDAD_INT NULL NULL NULL NULL NULL FX_DATOS_INI FX_DATOS_FIN
2 "ARGANZUELA" 202 "ACACIAS" 2 2094 94 " 47" 6 16 0 0 NULL "2024-07-01" "2024-07-01"
18 "VILLA DE VALLECAS" 1802 "SANTA EUGENIA" 2 18629 29 " 77" 7 3 0 2 NULL "2024-07-01" "2024-07-01"
Time taken: 0.047 seconds, Fetched: 3 row(s)
```

Ahora la tabla "buena"

```
hive> CREATE TABLE padron_parquet_2 (
  >   COD_DISTrito STRING,
  >   DESC_DISTrito STRING,
  >   COD_DIST_BARRIO STRING,
  >   DESC_BARRIO STRING,
  >   COD_BARRIO STRING,
  >   COD_DIST_SECCION STRING,
  >   COD_SECCION STRING,
  >   COD_EDAD_INT STRING,
  >   ESPANOLESHOMBRES STRING,
  >   ESPANOLESMUJERES STRING,
  >   EXTRANJEROSHOMBRES STRING,
  >   EXTRANJEROSMUJERES STRING,
  >   FX_CARGA STRING,
  >   FX_DATOS_INI STRING,
  >   FX_DATOS_FIN STRING
  > )
  > STORED AS PARQUET;
OK
Time taken: 0.049 seconds
```

```
hive> INSERT INTO padron_parquet_2 SELECT * FROM padron_txt_2;
```

Comprobación:

```
hive> select * from padron_parquet_2 limit 3;
OK
padron_parquet_2.cod_distrito padron_parquet_2.desc_distrito padron_parquet_2.cod_dist_barrio padron_parquet_2.desc_barrio padron_parquet_2.cod_barrio padron_parquet_2.cod_dist_seccion padron
t_2.fx_datos_ini padron_parquet_2.fx_datos_fin padron_parquet_2.espanoleshombres padron_parquet_2.espanolesmujeres padron_parquet_2.extranjeroshombres padron_parquet_2.extranjerosmujeres padron
2 ARGANZUELA 282 ACACIAS 2 2094 94 47 6 16 0 0 2024-07-07 00:00:01.8166596 2024-07-01 2024-07-01
18 VILLA DE VALLECAS 1882 SANTA EUGENIA 2 18829 29 77 7 3 0 2 2024-07-07 00:00:01.8166596 2024-07-01 2024-07-01
2 ARGANZUELA 285 DELICIAS 5 2062 62 71 6 6 0 2 2024-07-07 00:00:01.8166596 2024-07-01 2024-07-01
Time taken: 0.047 seconds, Fetched: 3 row(s)
```

## • 2.5) Investigar en qué consiste el formato columnar parquet y las ventajas de trabajar con este tipo de formatos.

Parquet es un formato de almacenamiento columnar que organiza los datos por columnas en lugar de filas. Esto permite una compresión eficiente y reduce el tamaño del almacenamiento. Su diseño facilita la lectura rápida de solo las columnas necesarias para consultas, mejorando el rendimiento en el procesamiento de datos. Además, Parquet es compatible con herramientas de Big Data como Apache Spark y Hive, y permite la evolución del esquema sin afectar los datos existentes.

## • 2.6) Comparar el tamaño de los ficheros de los datos de las tablas padron\_txt (txt), padron\_txt\_2 (txt pero no incluye los espacios innecesarios), padron\_parquet y padron\_parquet\_2 (alojados en hdfs cuya ruta se puede obtener de la propiedad location de cada tabla por ejemplo haciendo "show create table").

Para ello se pillará de cada tabla su LOCATION, accediendo a ellas con el siguiente comando:

```
hive> SHOW CREATE TABLE PADRON_TXT;
LOCATION
'hdfs://quickstart.cloudera:8020/user/hive/warehouse/padron_txt'
LOCATION
'hdfs://quickstart.cloudera:8020/user/hive/warehouse/padron_txt_2'
LOCATION
'hdfs://quickstart.cloudera:8020/user/hive/warehouse/padron_parquet'
LOCATION
'hdfs://quickstart.cloudera:8020/user/hive/warehouse/padron_parquet_2'
```

```
[cloudera@quickstart ~]$ hdfs dfs -du -h /user/hive/warehouse/padron_txt;
32.5 M  32.5 M  /user/hive/warehouse/padron_txt/padron.csv
[cloudera@quickstart ~]$ hdfs dfs -du -h /user/hive/warehouse/padron_txt_2;
32.5 M  32.5 M  /user/hive/warehouse/padron_txt_2/padron.csv
[cloudera@quickstart ~]$ hdfs dfs -du -h /user/hive/warehouse/padron_parquet;
2.4 M   2.4 M   /user/hive/warehouse/padron_parquet/0000000_0
[cloudera@quickstart ~]$ hdfs dfs -du -h /user/hive/warehouse/padron_parquet_2;
2.4 M   2.4 M   /user/hive/warehouse/padron_parquet_2/0000000_0
```

Se puede ver que Parquet ocupa 30 M menos que txt, lo que es sensacional para trabajar con datos grandes.

## 3- Juguemos con Impala.

### • 3.1) ¿Qué es Impala?

Impala es un motor de consultas SQL de código abierto para Hadoop, diseñado para ofrecer consultas rápidas y analíticas en grandes volúmenes de datos. Lee datos directamente desde HDFS y Apache HBase, usa procesamiento en memoria para mejorar la velocidad, y es compatible con SQL estándar.



Es ideal para análisis en tiempo real, escalabilidad horizontal y se integra con herramientas de BI para crear dashboards y reportes.

### • 3.2) ¿En qué se diferencia de Hive?

Impala y Hive son motores SQL para Hadoop con diferencias notables. Impala es más rápido y ofrece consultas interactivas en tiempo real al procesar datos en memoria, mientras que Hive, que usa MapReduce o Tez, puede ser más lento debido a la escritura en disco. Impala también se integra bien con HBase, permitiendo consultas sobre datos NoSQL, mientras que Hive se usa principalmente con HDFS. Impala está optimizado para consultas rápidas y complejas, mientras que Hive es más adecuado para procesamiento por lotes y tareas ETL.

### • 3.3) Comando INVALIDATE METADATA, ¿en qué consiste?

Se utiliza para forzar la actualización de la caché de metadatos de la base de datos. Esto es necesario cuando los metadatos de las tablas o particiones han cambiado fuera de Impala, como al agregar, eliminar o modificar archivos de datos. Ejecutar este comando garantiza que Impala lea los metadatos actualizados y refleje los cambios en las consultas posteriores.

### • 3.4) Hacer invalidate metadata en Impala de la base de datos datos\_padron.

Entro en Impala:

```
[cloudera@quickstart ~]$ impala-shell
Starting Impala Shell without Kerberos authentication
Connected to quickstart.cloudera:21000
Server version: impalad version 2.10.0-cdh5.13.0 RELEASE (build 2511805f1eaa991df1460276c7e9f19d819cd4e4)
*****
Welcome to the Impala shell.
(Impala Shell v2.10.0-cdh5.13.0 (2511805) built on Wed Oct 4 10:55:37 PDT 2017)

Want to know what version of Impala you're connected to? Run the VERSION command to
find out!
*****

[quickstart.cloudera:21000] > INVALIDATE METADATA datos_padron.padron_txt;
Query: invalidate METADATA datos_padron.padron_txt
Query submitted at: 2024-07-31 12:51:39 (Coordinator: http://quickstart.cloudera:25000)
Query progress can be monitored at: http://quickstart.cloudera:25000/query_plan?query_id=e94f811570d74aff:87a7489c00000000
Fetched 0 row(s) in 0.17s

[quickstart.cloudera:21000] > INVALIDATE METADATA datos_padron.padron_txt_2;
Query: invalidate METADATA datos_padron.padron_txt_2
Query submitted at: 2024-07-31 12:52:03 (Coordinator: http://quickstart.cloudera:25000)
Query progress can be monitored at: http://quickstart.cloudera:25000/query_plan?query_id=4245a405523548f1:5500b64b00000000
Fetched 0 row(s) in 0.12s
```

### • 3.5) 3.6) Calcular el total de EspanolesHombres, espanolesMujeres, ExtranjerosHombres y ExtranjerosMujeres agrupado por DESC\_DISTrito y DESC\_BARRIO.

Llevar a cabo las consultas en Hive en las tablas padron\_txt\_2 y padron\_parquet\_2 (No deberían incluir espacios innecesarios). ¿Alguna conclusión?

```
hive> SELECT
>     DESC_DISTrito,
>     DESC_BARRIO,
>     SUM(ESPAÑOLES_HOMBRES) AS Total_EspanolesHombres,
>     SUM(ESPAÑOLES_MUJERES) AS Total_EspanolesMujeres,
>     SUM(EXTRANJEROS_HOMBRES) AS Total_ExtranjerosHombres,
>     SUM(EXTRANJEROS_MUJERES) AS Total_ExtranjerosMujeres
> FROM
>     datos_padron.padron_txt_2
> GROUP BY
>     DESC_DISTrito,
>     DESC_BARRIO;
```



| desc_distrito | desc_barrio | total_espanoleshombres | total_espanolesmujeres | total_extranjeroshombres | total_extranjerosmujeres |
|---------------|-------------|------------------------|------------------------|--------------------------|--------------------------|
| ARGANZUELA    | 2.0 4.0     | 1.0 0.0                | 0.0                    | 1.0 0.0                  | 0.0                      |
| ARGANZUELA    | ACACIAS     | 15297.0                | 17871.0                | 1636.0                   | 1895.0                   |
| ARGANZUELA    | ATOCHA      | 899.0                  | 921.0                  | 129.0                    | 152.0                    |
| ARGANZUELA    | CHOPERA     | 7786.0                 | 9357.0                 | 1635.0                   | 1806.0                   |

Ahora en parquet...

```
hive> SELECT
>   DESC_DISTRITO,
>   DESC_BARRIO,
>   SUM(ESPANOLESHOMBRES) AS Total_EspanolesHombres,
>   SUM(ESPANOLESMUJERES) AS Total_EspanolesMujeres,
>   SUM(EXTRANJEROSHOMBRES) AS Total_ExtranjerosHombres,
>   SUM(EXTRANJEROSMUJERES) AS Total_ExtranjerosMujeres
> FROM
>   padron_parquet_2
> GROUP BY
>   DESC_DISTRITO,
>   DESC_BARRIO;
```

| desc_distrito | desc_barrio | total_espanoleshombres | total_espanolesmujeres | total_extranjeroshombres | total_extranjerosmujeres |
|---------------|-------------|------------------------|------------------------|--------------------------|--------------------------|
| NULL NULL     | NULL NULL   | NULL NULL              |                        |                          |                          |
| ARGANZUELA    | ACACIAS     | 15297.0                | 17871.0                | 1636.0                   | 1895.0                   |
| ARGANZUELA    | ATOCHA      | 899.0                  | 921.0                  | 129.0                    | 152.0                    |
| ARGANZUELA    | CHOPERA     | 7786.0                 | 9357.0                 | 1635.0                   | 1806.0                   |
| ARGANZUELA    | DELICIAS    | 11928.0                | 13417.0                | 2098.0                   | 2331.0                   |

### • 3.7) 3.8) Llevar a cabo la misma consulta sobre las mismas tablas en Impala.

¿Alguna conclusión?

¿Se percibe alguna diferencia de rendimiento entre Hive e Impala?

```
[quickstart.cloudera:21000] > SELECT
>   DESC_DISTRITO,
>   DESC_BARRIO,
>   SUM(CAST(ESPANOLESHOMBRES AS INT)) AS Total_Es
panolesHombres,
>   SUM(CAST(ESPANOLESMUJERES AS INT)) AS Total_Es
panolesMujeres,
>   SUM(CAST(EXTRANJEROSHOMBRES AS INT)) AS Total_
ExtranjerosHombres,
>   SUM(CAST(EXTRANJEROSMUJERES AS INT)) AS Total_
ExtranjerosMujeres
> FROM
>   default.padron_parquet_2
> GROUP BY
>   DESC_DISTRITO,
>   DESC_BARRIO;
```

| desc_distrito | desc_barrio     | total_espanoleshombres | total_espanolesmujeres | total_extranjeroshombres | total_extranjerosmujeres |
|---------------|-----------------|------------------------|------------------------|--------------------------|--------------------------|
| ARGANZUELA    | LEGAZPI         | 8956                   | 9338                   |                          |                          |
|               | 859             | 950                    |                        |                          |                          |
| CHAMBERI      | RIOS ROSAS      | 10525                  | 13407                  |                          |                          |
|               | 1915            | 2397                   |                        |                          |                          |
| BARAJAS       | CASCO H.BARAJAS | 2983                   | 3182                   |                          |                          |
|               | 832             | 955                    |                        |                          |                          |
| USERA         | ORCASITAS       | 9758                   | 10971                  |                          |                          |
|               | 1480            | 1650                   |                        |                          |                          |
| BARAJAS       | TTMM            | 5276                   | 5805                   |                          |                          |

En impala he percibido que la ejecución se ha realizado mucho más rápido que en hive, me ha sorprendido lo rápido que ha extraído los datos. Impala es más rápido que Hive porque ejecuta consultas en memoria y usa un motor de procesamiento distribuido optimizado, mientras que Hive utiliza MapReduce, que es más lento debido a su enfoque en disco.

## 4- Sobre tablas particionadas.

- 4.1) Crear tabla (Hive) padron\_particionado particionada por campos DESC\_DISTRITO y DESC\_BARRIO cuyos datos estén en formato parquet.

```
hive> CREATE TABLE padron_particionado (  
  >   COD_DISTRITO INT,  
  >   COD_DIST_BARRIO INT,  
  >   COD_BARRIO INT,  
  >   COD_DIST_SECCION INT,  
  >   COD_SECCION INT,  
  >   COD_EDAD INT STRING,  
  >   ESPANOLESHOMBRES INT,  
  >   ESPANOLESMUJERES INT,  
  >   EXTRANJEROSHOMBRES INT,  
  >   EXTRANJEROSMUJERES INT,  
  >   FX_CARGA STRING,  
  >   FX_DATOS_INI STRING,  
  >   FX_DATOS_FIN STRING  
  > )  
  > PARTITIONED BY (DESC_DISTRITO STRING, DESC_BARRIO STRING)  
  > STORED AS PARQUET;  
OK
```

- 4.2) Insertar datos (en cada partición) dinámicamente (con Hive) en la tabla recién creada a partir de un select de la tabla padron\_parquet\_2.

Me ha dado un error en la inserción de datos ya que me indicaba que Hive intentaba crear demasiadas particiones dinámicas. Este problema es común cuando se intenta particionar por columnas con una alta cardinalidad sin ajustar los límites de particiones dinámicas.

Para resolverlo, he incrementado los límites de particion:

```
hive> SET hive.exec.max.dynamic.partitions = 1000;  
hive> SET hive.exec.max.dynamic.partitions.pernode = 1000;
```

```
hive> INSERT INTO TABLE padron_particionado PARTITION (DESC_DISTRITO, DESC_BARRIO)  
  > SELECT  
  >   COD_DISTRITO,  
  >   COD_DIST_BARRIO,  
  >   COD_BARRIO,  
  >   COD_DIST_SECCION,  
  >   COD_SECCION,  
  >   COD_EDAD INT,  
  >   ESPANOLESHOMBRES,  
  >   ESPANOLESMUJERES,  
  >   EXTRANJEROSHOMBRES,  
  >   EXTRANJEROSMUJERES,  
  >   FX_CARGA,  
  >   FX_DATOS_INI,  
  >   FX_DATOS_FIN,  
  >   DESC_DISTRITO,  
  >   DESC_BARRIO  
  > FROM padron_parquet_2;
```

- 4.3) Hacer invalidate metadata en Impala de la base de datos padron\_particionado.

```
[quickstart.cloudera:21000] > INVALIDATE METADATA default.padron_particionado;
```

```
[quickstart.cloudera:21000] > SHOW TABLES;  
Query: show TABLES
```

| name                |
|---------------------|
| empleados           |
| padron2             |
| padron_parquet      |
| padron_parquet_2    |
| padron_particionado |

Vemos que aparece aqui.

• 4.4) • 4.5) Calcular el total de EspanolesHombres, EspanolesMujeres, ExtranjerosHombres y ExtranjerosMujeres agrupado por DESC\_DISTRITO y DESC\_BARRIO para los distritos CENTRO, LATINA, CHAMARTIN, TETUAN, VICALVARO y BARAJAS.

Llevar a cabo la consulta en Hive en las tablas padron\_parquet y padron\_particionado. ¿Alguna conclusión?

```
hive> SELECT
>     DESC_DISTRITO,
>     DESC_BARRIO,
>     SUM(ESPANOLESHOMBRES) AS Total_EspanolesHombres,
>     SUM(ESPANOLESMUJERES) AS Total_EspanolesMujeres,
>     SUM(EXTRANJEROSHOMBRES) AS Total_ExtranjerosHombres,
>     SUM(EXTRANJEROSMUJERES) AS Total_ExtranjerosMujeres
> FROM
>     default.padron_parquet
> WHERE
>     DESC_DISTRITO IN ('CENTRO', 'LATINA', 'CHAMARTIN', 'TETUAN', 'VICALVARO', 'BARAJAS')
> GROUP BY
>     DESC_DISTRITO,
>     DESC_BARRIO;
```

```
hive> SELECT
>     DESC_DISTRITO,
>     DESC_BARRIO,
>     SUM(ESPANOLESHOMBRES) AS Total_EspanolesHombres,
>     SUM(ESPANOLESMUJERES) AS Total_EspanolesMujeres,
>     SUM(EXTRANJEROSHOMBRES) AS Total_ExtranjerosHombres,
>     SUM(EXTRANJEROSMUJERES) AS Total_ExtranjerosMujeres
> FROM
>     default.padron_particionado
> WHERE
>     DESC_DISTRITO IN ('CENTRO', 'LATINA', 'CHAMARTIN', 'TETUAN', 'VICALVARO', 'BARAJAS')
> GROUP BY
>     DESC_DISTRITO,
>     DESC_BARRIO;
```

La particionada se realiza a mayor velocidad, ya que al estar particionada, no tiene que leer toda la tabla completa, por lo que es más eficiente, por lo que la tabla particionada, mejora el rendimiento de la consulta.

• 4.6) Llevar a cabo la consulta en Impala en las tablas padron\_parquet y padron\_particionado. ¿Alguna conclusión?

```
[quickstart.cloudera:21000] > SELECT
>     DESC_DISTRITO,
>     DESC_BARRIO,
>     SUM(CAST(ESPANOLESHOMBRES AS INT)) AS Total_EspanolesHombres,
>     SUM(CAST(ESPANOLESMUJERES AS INT)) AS Total_EspanolesMujeres,
>     SUM(CAST(EXTRANJEROSHOMBRES AS INT)) AS Total_ExtranjerosHombres,
>     SUM(CAST(EXTRANJEROSMUJERES AS INT)) AS Total_ExtranjerosMujeres
> FROM
>     default.padron_parquet
> WHERE
>     DESC_DISTRITO IN ('CENTRO', 'LATINA', 'CHAMARTIN', 'TETUAN', 'VICALVARO', 'BARAJAS')
> GROUP BY
>     DESC_DISTRITO,
>     DESC_BARRIO;

Query: select DESC_DISTRITO,
DESC_BARRIO,
SUM(CAST(ESPANOLESHOMBRES AS INT)) AS Total_EspanolesHombres,
SUM(CAST(ESPANOLESMUJERES AS INT)) AS Total_EspanolesMujeres,
SUM(CAST(EXTRANJEROSHOMBRES AS INT)) AS Total_ExtranjerosHombres,
SUM(CAST(EXTRANJEROSMUJERES AS INT)) AS Total_ExtranjerosMujeres
FROM
default.padron_parquet
WHERE
DESC_DISTRITO IN ('CENTRO', 'LATINA', 'CHAMARTIN', 'TETUAN', 'VICALVARO', 'BARAJAS')
GROUP BY
DESC_DISTRITO,
DESC_BARRIO
Query submitted at: 2024-07-31 14:11:32 (Coordinator: http://quickstart.cloudera:25000)
Query progress can be monitored at: http://quickstart.cloudera:25000/query_plan?query_id=e645ae6b285864d8:9ce80cf100000000
Fetched 0 row(s) in 0.39s
```

```
[quickstart.cloudera:21000] > SELECT
>     DESC_DISTRITO,
>     DESC_BARRIO,
>     SUM(CAST(ESPAÑOLES_HOMBRES AS INT)) AS Total_EspanolesHombres,
>     SUM(CAST(ESPAÑOLES_MUJERES AS INT)) AS Total_EspanolesMujeres,
>     SUM(CAST(EXTRANJEROS_HOMBRES AS INT)) AS Total_ExtranjerosHombres,
>     SUM(CAST(EXTRANJEROS_MUJERES AS INT)) AS Total_ExtranjerosMujeres
> FROM
>     default.padron_particionado
> WHERE
>     DESC_DISTRITO IN ('CENTRO', 'LATINA', 'CHAMARTIN', 'TETUAN', 'VICALVARO', 'BARAJAS')
> GROUP BY
>     DESC_DISTRITO,
>     DESC_BARRIO;

Query: select DESC_DISTRITO,
DESC_BARRIO,
SUM(CAST(ESPAÑOLES_HOMBRES AS INT)) AS Total_EspanolesHombres,
SUM(CAST(ESPAÑOLES_MUJERES AS INT)) AS Total_EspanolesMujeres,
SUM(CAST(EXTRANJEROS_HOMBRES AS INT)) AS Total_ExtranjerosHombres,
SUM(CAST(EXTRANJEROS_MUJERES AS INT)) AS Total_ExtranjerosMujeres
FROM
default.padron_particionado
WHERE
DESC_DISTRITO IN ('CENTRO', 'LATINA', 'CHAMARTIN', 'TETUAN', 'VICALVARO', 'BARAJAS')
GROUP BY
DESC_DISTRITO,
DESC_BARRIO
Query submitted at: 2024-07-31 14:15:09 (Coordinator: http://quickstart.cloudera:25000)
Query progress can be monitored at: http://quickstart.cloudera:25000/query_plan?query_id=4e4072b79fd0423e:107ba00d00000000
Fetched 0 row(s) in 4.45s
```

En Impala, la ejecución de consultas es mucho más rápida que en Hive, ya que Impala procesa datos en memoria con un motor distribuido optimizado, mientras que Hive usa MapReduce, más lento por su enfoque en disco. Además, las tablas particionadas en Hive mejoran el rendimiento porque solo leen las particiones relevantes en lugar de toda la tabla.

• **4.7) Hacer consultas de agregación (Max, Min, Avg, Count) tal cual el ejemplo anterior con las 3 tablas (padron\_txt\_2, padron\_parquet\_2 y padron\_particionado) y comparar rendimientos tanto en Hive como en Impala y sacar conclusiones.**

En Impala:

```
[quickstart.cloudera:21000] > SELECT
>     DESC_DISTRITO,
>     DESC_BARRIO,
>     SUM(CAST(ESPAÑOLES_HOMBRES AS INT)) AS Total_EspanolesHombres,
>     SUM(CAST(ESPAÑOLES_MUJERES AS INT)) AS Total_EspanolesMujeres,
>     SUM(CAST(EXTRANJEROS_HOMBRES AS INT)) AS Total_ExtranjerosHombres,
>     SUM(CAST(EXTRANJEROS_MUJERES AS INT)) AS Total_ExtranjerosMujeres
> FROM
>     default.padron_parquet_2
> WHERE
>     DESC_DISTRITO IN ('CENTRO', 'LATINA', 'CHAMARTIN', 'TETUAN', 'VICALVARO', 'BARAJAS')
> GROUP BY
>     DESC_DISTRITO,
>     DESC_BARRIO;

Query: select DESC_DISTRITO,
DESC_BARRIO,
SUM(CAST(ESPAÑOLES_HOMBRES AS INT)) AS Total_EspanolesHombres,
SUM(CAST(ESPAÑOLES_MUJERES AS INT)) AS Total_EspanolesMujeres,
SUM(CAST(EXTRANJEROS_HOMBRES AS INT)) AS Total_ExtranjerosHombres,
SUM(CAST(EXTRANJEROS_MUJERES AS INT)) AS Total_ExtranjerosMujeres
FROM
default.padron_parquet_2
WHERE
DESC_DISTRITO IN ('CENTRO', 'LATINA', 'CHAMARTIN', 'TETUAN', 'VICALVARO', 'BARAJAS')
GROUP BY
DESC_DISTRITO,
DESC_BARRIO
Query submitted at: 2024-07-31 14:19:10 (Coordinator: http://quickstart.cloudera:25000)
Query progress can be monitored at: http://quickstart.cloudera:25000/query_plan?query_id=524a4648130af07a:dde9895000000000
Fetched 0 row(s) in 0.43s
```

En Hive:

```
hive> SELECT
>     DESC_DISTRITO,
>     DESC_BARRIO,
>     SUM(CAST(ESPAÑOLES_HOMBRES AS INT)) AS Total_EspanolesHombres,
>     SUM(CAST(ESPAÑOLES_MUJERES AS INT)) AS Total_EspanolesMujeres,
>     SUM(CAST(EXTRANJEROS_HOMBRES AS INT)) AS Total_ExtranjerosHombres,
>     SUM(CAST(EXTRANJEROS_MUJERES AS INT)) AS Total_ExtranjerosMujeres
> FROM
>     default.padron_txt_2
> WHERE
>     DESC_DISTRITO IN ('CENTRO', 'LATINA', 'CHAMARTIN', 'TETUAN', 'VICALVARO', 'BARAJAS')
> GROUP BY
>     DESC_DISTRITO,
>     DESC_BARRIO;
```

En memoria con un motor distribuido optimizado, mientras que Hive usa MapReduce, más lento por su enfoque en disco. Además, las tablas particionadas en Hive mejoran el rendimiento porque solo leen las particiones relevantes en lugar de toda la tabla.

## 5- Trabajando con tablas en HDFS.

A continuación vamos a hacer una inspección de las tablas, tanto externas (no gestionadas) como internas (gestionadas). Este apartado se hará si se tiene acceso y conocimiento previo sobre cómo insertar datos en HDFS.

- 5.1) Crear un documento de texto en el almacenamiento local que contenga una secuencia de números distribuidos en filas y separados por columnas, llámalo datos1 y que sea por ejemplo: 1,2,3 4,5,6 7,8,9



datos1.txt

- 5.2) Crear un segundo documento (datos2) con otros números pero la misma estructura.



datos2.txt

- 5.3) Crear un directorio en HDFS con un nombre a placer, por ejemplo, /test. Si estás en una máquina Cloudera tienes que asegurarte de que el servicio HDFS está activo ya que puede no iniciarse al encender la máquina (puedes hacerlo desde el Cloudera Manager). A su vez, en las máquinas Cloudera es posible (dependiendo de si usamos Hive desde consola o desde Hue) que no tengamos permisos para crear directorios en HDFS salvo en el directorio /user/cloudera.

```
[cloudera@quickstart ~]$ hdfs dfs -mkdir /user/cloudera/test
[cloudera@quickstart ~]$ hdfs dfs -ls /user/cloudera
Found 5 items
drwxrwxrwx - cloudera cloudera      0 2024-07-10 11:42 /user/cloudera/ejercicios
drwxrwxrwx - cloudera cloudera      0 2024-07-11 14:05 /user/cloudera/ejercicios_master
drwxrwxrwx - cloudera cloudera      0 2024-07-10 13:37 /user/cloudera/terasort-input
drwxrwxrwx - cloudera cloudera      0 2024-07-10 13:38 /user/cloudera/terasort-output
drwxr-xr-x - cloudera cloudera      0 2024-07-31 14:31 /user/cloudera/test
```

- 5.4) Mueve tu fichero datos1 al directorio que has creado en HDFS con un comando desde consola.

```
[cloudera@quickstart ~]$ cd /home/cloudera/Desktop/Padron/
[cloudera@quickstart Padron]$ hdfs dfs -put datos1.txt /user/cloudera/test/
[cloudera@quickstart Padron]$ hdfs dfs -ls /user/cloudera/test/
Found 1 items
-rw-r--r--  1 cloudera cloudera      18 2024-07-31 14:33 /user/cloudera/test/datos1.txt
```

- 5.5) Desde Hive, crea una nueva database por ejemplo con el nombre **numeros**. Crea una tabla que no sea externa y sin argumento location con tres columnas numéricas, campos separados por coma y delimitada por filas. La llamaremos por ejemplo **numeros\_tbl**.

```
hive> CREATE DATABASE numeros;
OK
Time taken: 0.343 seconds
hive> USE numeros;
OK
Time taken: 0.023 seconds
hive> CREATE TABLE numeros_tbl (
  >   num1 INT,
  >   num2 INT,
  >   num3 INT
  > )
  > ROW FORMAT DELIMITED
  > FIELDS TERMINATED BY ','
  > LINES TERMINATED BY '\n';
OK
Time taken: 0.244 seconds
```

- 5.6) Carga los datos de nuestro fichero de texto **datos1** almacenado en HDFS en la tabla de Hive. Consulta la localización donde estaban anteriormente los datos almacenados. ¿Siguen estando ahí? ¿Dónde están?. Borra la tabla, ¿qué ocurre con los datos almacenados en HDFS?

Inserción de datos...

```
hive> LOAD DATA INPATH '/user/cloudera/test/datos1.txt' INTO TABLE numeros_tbl;
Loading data to table numeros.numeros_tbl
Table numeros.numeros_tbl stats: [numFiles=1, totalSize=18]
OK
Time taken: 0.311 seconds
hive> select * from numeros_tbl;
OK
numeros_tbl.num1      numeros_tbl.num2      numeros_tbl.num3
1          2          3
4          5          6
7          8          9
Time taken: 0.285 seconds, Fetched: 3 row(s)
```

Vemos donde estaban almacenados los datos antes...

```
hive> DESCRIBE FORMATTED numeros_tbl;
Location:                  hdfs://quickstart.cloudera:8020/user/hive/warehouse/numeros.db/numeros_tbl
```

Vemos que después de eliminar la tabla no aparece:

```
[cloudera@quickstart Padron]$ hdfs dfs -ls /user/cloudera/test/;
```

Esto se debe a...

1. La tabla en Hive no es externa: En Hive, si la tabla no está definida como externa y eliminas la tabla con **DROP TABLE**, Hive eliminará automáticamente los datos almacenados en HDFS asociados a esa tabla.
2. Ubicación predeterminada de la tabla: Si no se especifica una ubicación externa personalizada para la tabla, los datos se almacenan en la ubicación predeterminada de Hive, que se encuentra en **/user/hive/warehouse** (o similar). Al eliminar la tabla, Hive elimina tanto la definición de la tabla como los datos en la ubicación predeterminada. **(es el caso)**

- **5.7) Vuelve a mover el fichero de texto datos1 desde el almacenamiento local al directorio anterior en HDFS.**

```
[cloudera@quickstart Padron]$ hdfs dfs -put datos1.txt /user/cloudera/test
[cloudera@quickstart Padron]$ hdfs dfs -ls /user/cloudera/test
Found 1 items
-rw-r--r--  1 cloudera cloudera          18 2024-07-31 14:48 /user/cloudera/test
/datos1.txt
```

- **5.8) Desde Hive, crea una tabla externa sin el argumento location. Y carga datos1 (desde HDFS) en ella. ¿A dónde han ido los datos en HDFS? Borra la tabla ¿Qué ocurre con los datos en hdfs?**

```
hive> CREATE EXTERNAL TABLE numeros_externos (
>   col1 INT,
>   col2 INT,
>   col3 INT
> )
> ROW FORMAT DELIMITED
> FIELDS TERMINATED BY ','
> LINES TERMINATED BY '\n';
OK
Time taken: 1.52 seconds

hive> LOAD DATA INPATH '/user/cloudera/test/datos1.txt' INTO TABLE numeros_externos;
Loading data to table numeros.numeros_externos
Table numeros.numeros_externos stats: [numFiles=1, numRows=0, totalSize=18, rawDataSize=0]
OK
Time taken: 0.225 seconds
```

Una vez hecha la inserción, se puede comprobar que los datos están en hdfs:

```
[cloudera@quickstart Padron]$ hdfs dfs -ls /user/cloudera/test
Found 1 items
-rwxr-xr-x  1 cloudera cloudera          18 2024-08-01 08:18 /user/cloudera/test
/datos1.txt
```

Borro la tabla...

```
hive> drop table numeros_externos;
OK
Time taken: 0.359 seconds
```

Compruebo si siguen los datos...

```
[cloudera@quickstart Padron]$ hdfs dfs -ls /user/cloudera/test
Found 1 items
-rwxr-xr-x  1 cloudera cloudera          18 2024-08-01 08:18 /user/cloudera/test
/datos1.txt
```

Los datos permanecen en HDFS a pesar de eliminar la tabla externa en Hive porque:

- **Tabla externa:** Al crear una tabla externa, Hive solo gestiona la metadata y no los datos.
- **Eliminar la tabla:** Eliminar una tabla externa en Hive solo elimina la metadata de la tabla, pero no los datos en HDFS.

Así, los datos siguen existiendo en HDFS después de la eliminación de la tabla externa en Hive.



- **5.9) Borra el fichero datos1 del directorio en el que estén. Vuelve a insertarlos en el directorio que creamos inicialmente (/test). Vuelve a crear la tabla numeros desde hive pero ahora de manera externa y con un argumento location que haga referencia al directorio donde los hayas situado en HDFS (/test). No cargues los datos de ninguna manera explícita. Haz una consulta sobre la tabla que acabamos de crear que muestre todos los registros. ¿Tiene algún contenido?**

```
[cloudera@quickstart Padron]$ hdfs dfs -rm /user/cloudera/test/datos1.txt
Deleted /user/cloudera/test/datos1.txt
[cloudera@quickstart Padron]$ hdfs dfs -put datos1.txt /user/cloudera/test/
[cloudera@quickstart Padron]$ hdfs dfs -ls /user/cloudera/test
Found 1 items
-rw-r--r--  1 cloudera cloudera      18 2024-08-01 08:26 /user/cloudera/test
/datos1.txt
```

```
hive> CREATE EXTERNAL TABLE numeros_externos (
>     num1 INT,
>     num2 INT,
>     num3 INT
> )
> ROW FORMAT DELIMITED
> FIELDS TERMINATED BY ','
> LINES TERMINATED BY '\n'
> LOCATION '/user/cloudera/test';
```

OK

Time taken: 0.066 seconds

```
hive> SELECT * FROM numeros_externos;
```

OK

```
numeros_externos.num1  numeros_externos.num2  numeros_externos.num3
1      2      3
4      5      6
7      8      9
```

Time taken: 0.37 seconds, Fetched: 3 row(s)

La tabla externa se refiere directamente a los datos en HDFS. No es necesario cargar los datos explícitamente en la tabla ya que Hive mapea directamente al archivo o directorio especificado en **LOCATION**. Por lo tanto, al hacer la consulta, los datos presentes en el archivo **datos1** en el directorio **/test** serán mostrados.

- **5.10) Inserta el fichero de datos creado al principio, "datos2" en el mismo directorio de HDFS que "datos1". Vuelve a hacer la consulta anterior sobre la misma tabla. ¿Qué salida muestra?**

```
[cloudera@quickstart Padron]$ hdfs dfs -put datos2.txt /user/cloudera/test/
[cloudera@quickstart Padron]$ hdfs dfs -ls /user/cloudera/test
Found 2 items
-rw-r--r--  1 cloudera cloudera      18 2024-08-01 08:26 /user/cloudera/test
/datos1.txt
-rw-r--r--  1 cloudera cloudera      27 2024-08-01 08:34 /user/cloudera/test
/datos2.txt
```

```
hive> SELECT * FROM numeros_externos;
OK
numeros_externos.num1  numeros_externos.num2  numeros_externos.num3
1      2      3
4      5      6
7      8      9
10     21     32
43     54     65
76     87     98
Time taken: 0.06 seconds, Fetched: 6 row(s)
```

Como insertamos de nuevo en la carpeta a la que hace referencia la tabla, todos los datos que metamos dentro de esa carpeta, los podremos utilizar ya que la tabla pilla su referencia, por lo que podemos sacar como conclusión que trabajar con 'LOCATION', es una forma bastante eficiente y fácil de usar, que nos permite trabajar de una manera más cómoda.

#### • 5.11) Extrae conclusiones de todos estos anteriores apartados.

1. Rendimiento de Hive vs. Impala:
  - Impala: Observamos que las consultas en Impala se ejecutan mucho más rápido que en Hive. Esto se debe a que Impala ejecuta las consultas en memoria y utiliza un motor de procesamiento distribuido optimizado. Esto contrasta con Hive, que utiliza MapReduce, un enfoque más lento debido a su operación basada en disco.
  - Tablas particionadas: Las tablas particionadas ofrecen un mejor rendimiento en las consultas porque no necesitan leer toda la tabla, sino solo las particiones relevantes. Esto mejora significativamente la eficiencia de las consultas.
2. Operaciones con tablas en Hive:
  - Carga de datos en tablas Hive:
    - Al cargar datos en una tabla interna de Hive, los datos se mueven desde su ubicación original en HDFS al directorio gestionado por Hive. Esto hace que los datos desaparezcan de su ubicación original una vez que se cargan en la tabla.
    - Si se elimina una tabla interna, los datos almacenados en HDFS también se eliminan.
  - Tablas externas en Hive:
    - Al crear y cargar datos en una tabla externa, Hive no mueve los datos, sino que los referencia directamente desde su ubicación original en HDFS. Esto significa que los datos permanecen en su lugar original.
    - Al eliminar una tabla externa, los datos en HDFS no se eliminan porque Hive no es el propietario de los datos, solo los referencia.
3. Gestión de archivos en HDFS:
  - Borrar y mover archivos en HDFS:
    - Los comandos HDFS (`hdfs dfs -rm` y `hdfs dfs -put`) permiten gestionar los archivos y directorios en el sistema de archivos distribuido.
  - Creación de directorios y archivos:
    - Creamos directorios en HDFS para organizar y almacenar datos, facilitando su referencia desde Hive.
  - Persistencia de datos:
    - Los datos cargados en tablas externas en Hive permanecen en su ubicación original en HDFS incluso después de eliminar la tabla, lo cual es útil para la gestión y persistencia de grandes volúmenes de datos.
4. Resumen general:
  - Impala es altamente eficiente para consultas rápidas debido a su enfoque en memoria.
  - Hive es útil para operaciones ETL y manipulación de datos debido a su integración con Hadoop y su capacidad para manejar grandes volúmenes de datos.
  - Tablas particionadas mejoran el rendimiento al reducir la cantidad de datos leídos durante las consultas.
  - Tablas externas en Hive proporcionan flexibilidad para referenciar datos en HDFS sin moverlos, asegurando que los datos permanezcan accesibles incluso si la tabla se elimina.

Estas conclusiones resaltan las ventajas y consideraciones prácticas al utilizar herramientas de Big Data como Hive e Impala, así como la importancia de una adecuada gestión de datos en HDFS para un rendimiento y eficiencia óptimos.

La siguiente sección de la práctica se abordará si ya se tienen suficientes conocimientos de Spark, en concreto de el manejo de DataFrames, y el manejo de tablas de Hive a través de Spark.sql.

## 6- SPARK

- 6.1) Comenzamos realizando la misma práctica que hicimos en Hive en Spark, importando el csv. Sería recomendable intentarlo con opciones que quiten las "" de los campos, que ignoren los espacios innecesarios en los campos, que sustituyan los valores vacíos por 0 y que infiera el esquema.

```
%python
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, trim, when

spark = SparkSession.builder.appName("Padron").getOrCreate()

df = spark.read.csv("/FileStore/tables/Formacion_Binaia/Practica_Padron/estadisticas202407.csv",
                    header=True, #primera linea de archivo son columnas
                    inferSchema=True, #permite a spark inferir el tipo de datos de cada columna
                    sep=';', #separacion de campos
                    quote='\"', #indica que las comillas se usan para envolver campos
                    ignoreLeadingWhiteSpace=True, #ignora espacios en blanco al principio
                    ignoreTrailingWhiteSpace=True, #y al final de los campos
                    nullValue='', #celdas vacias como valores nulos
                    nanValue='0') #sustituye valores nan por 0

# Reemplazar valores nulos con 0
df = df.fillna(0)

# Eliminar espacios innecesarios en los campos
df = df.select([trim(col(c)).alias(c) for c in df.columns])

# Mostrar el esquema para confirmar que se infirió correctamente
df.printSchema()

# Mostrar algunas filas para verificar los datos
df.show(10)
```

|    | COD_DISTrito | DESC_DISTrito     | COD_DIST_BARRIO | DESC_BARRIO          | COD_DIST_SECCION | COD_SECCION | COD_EDAD_INT | ESPAÑOLSHOMBRES | ESPAÑOLSMUJERES | EXTRANJEROSHOMBRES | EXTRANJEROSMUJERES | FX_CARGA | FX_DATOS_INI | FX_DATOS_FIN |
|----|--------------|-------------------|-----------------|----------------------|------------------|-------------|--------------|-----------------|-----------------|--------------------|--------------------|----------|--------------|--------------|
| 16 | 2            | ARGANZUELA        | 202             | ACACIAS              | 2                | 2094        | 94           | 47              | 6               |                    |                    |          |              |              |
|    |              | 0                 | 0               | 2024-07-07 00:00:... | 2024-07-01       | 2024-07-01  |              |                 |                 |                    |                    |          |              |              |
|    | 18           | VILLA DE VALLECAS | 1802            | SANTA EUGENIA        | 2                | 18029       | 29           | 77              | 7               |                    |                    |          |              |              |
| 3  |              | 0                 | 2               | 2024-07-07 00:00:... | 2024-07-01       | 2024-07-01  |              |                 |                 |                    |                    |          |              |              |
|    | 2            | ARGANZUELA        | 205             | DELICIAS             | 5                | 2062        | 62           | 71              | 6               |                    |                    |          |              |              |
| 6  |              | 0                 | 2               | 2024-07-07 00:00:... | 2024-07-01       | 2024-07-01  |              |                 |                 |                    |                    |          |              |              |
|    | 9            | MONCLOA-ARAVACA   | 907             | ARAVACA              | 7                | 9083        | 83           | 55              | 15              |                    |                    |          |              |              |
| 14 |              | 0                 | 0               | 2024-07-07 00:00:... | 2024-07-01       | 2024-07-01  |              |                 |                 |                    |                    |          |              |              |
|    | 3            | RETIRO            | 306             | NIÑO JESUS           | 6                | 3080        | 80           | 60              | 7               |                    |                    |          |              |              |
| 8  | 1            |                   | 1               | 2024-07-07 00:00:... | 2024-07-01       | 2024-07-01  |              |                 |                 |                    |                    |          |              |              |
|    | 4            | SALAMANCA         | 405             | LISTA                | 5                | 4102        | 102          | 78              | 1               |                    |                    |          |              |              |
| 6  |              | 0                 | 0               | 2024-07-07 00:00:... | 2024-07-01       | 2024-07-01  |              |                 |                 |                    |                    |          |              |              |

- 6.2) De manera alternativa también se puede importar el csv con menos tratamiento en la importación y hacer todas las modificaciones para alcanzar el mismo estado de limpieza de los datos con funciones de Spark.

```
%python
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, trim, regexp_replace

# Crear una sesión de Spark
spark = SparkSession.builder.appName("Padron").getOrCreate()

# Leer el archivo CSV en un DataFrame de Spark con menos opciones de tratamiento inicial
df = spark.read.csv("/FileStore/tables/Formacion_Binaia/Practica_Padron/estadisticas202407.csv", header=True, sep=';')

# Mostrar el esquema inicial para ver cómo se cargaron los datos
df.printSchema()

# Reemplazar comillas dobles y espacios innecesarios en los campos
df = df.select([trim(regexp_replace(col(c), '"', '')).alias(c) for c in df.columns])

# Reemplazar valores vacíos con 0
df = df.fillna('0')

# Convertir las columnas adecuadas a int
int_columns = ['ESPAÑOLES_HOMBRES', 'ESPAÑOLES_MUJERES', 'EXTRANJEROS_HOMBRES', 'EXTRANJEROS_MUJERES']
for column in int_columns:
    df = df.withColumn(column, col(column).cast('int'))

# Mostrar el esquema para confirmar que se infirió correctamente
df.printSchema()

# Mostrar algunas filas para verificar los datos
df.show(10)
```

|    | COD_DISTRITO | DESC_DISTRITO     | COD_DIST_BARRIO | DESC_BARRIO          | COD_BARRIO | COD_DIST_SECCION | COD_SECCION | COD_EDAD_INT | ESPAÑOLES_HOMBRES | ESPAÑOLES_MUJERES | EXTRANJEROS_HOMBRES | EXTRANJEROS_MUJERES | FX_CARGA | FX_DATOS_INI | FX_DATOS_FIN |
|----|--------------|-------------------|-----------------|----------------------|------------|------------------|-------------|--------------|-------------------|-------------------|---------------------|---------------------|----------|--------------|--------------|
| 16 | 2            | ARGANZUELA        | 202             | ACACIAS              | 2          | 2094             | 94          | 47           | 6                 |                   |                     |                     |          |              |              |
|    | 18           | VILLA DE VALLECAS | 1802            | SANTA EUGENIA        | 2          | 18029            | 29          | 77           | 7                 |                   |                     |                     |          |              |              |
| 3  | 0            |                   | 2               | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01       |             |              |                   |                   |                     |                     |          |              |              |
|    | 2            | ARGANZUELA        | 205             | DELICIAS             | 5          | 2062             | 62          | 71           | 6                 |                   |                     |                     |          |              |              |
| 6  | 0            |                   | 2               | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01       |             |              |                   |                   |                     |                     |          |              |              |
|    | 9            | MONCLOA-ARAVACA   | 907             | ARAVACA              | 7          | 9083             | 83          | 55           | 15                |                   |                     |                     |          |              |              |
| 14 | 0            |                   | 0               | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01       |             |              |                   |                   |                     |                     |          |              |              |
|    | 3            | RETIRO            | 306             | NIÑO JESUS           | 6          | 3080             | 80          | 60           | 7                 |                   |                     |                     |          |              |              |

- 6.3) Enumera todos los barrios diferentes.

```
%python

# Enumerar todos los barrios diferentes
barrios_unicos = df.select('DESC_BARRIO').distinct().orderBy('DESC_BARRIO')

# Mostrar los barrios únicos
barrios_unicos.show(truncate=False)
```

► (2) Spark Jobs

► barrios\_unicos: pyspark.sql.dataframe.DataFrame = [DESC\_BARRIO: string]

```
|ABRANTES|
|ACACIAS|
|ADELFAS|
|AEROPUERTO|
|ALAMEDA DE OSUNA|
|ALMAGRO|
|ALMENARA|
|ALMENDRALES|
|ALUCHE|
|AMPOSTA|
|ANGELES|
|APOSTOL SANTIAGO|
|ARAPILES|
|ARAVACA|
|ARCOS|
|ARGUELLES|
|ATALAYA|
|ATOCHA|
|BELLAS VISTAS|
```

only showing top 20 rows

- 6.4) Crea una vista temporal de nombre "padron" y a través de ella cuenta el número de barrios diferentes que hay.

```
%python
#Una vista temporal permite ejecutar consultas SQL sobre datos que ya están en un DataFrame de Spark, sin tener que realizar el procesamiento de datos nuevamente.
# Crear una vista temporal
df.createOrReplaceTempView("padron")

# Contar el número de barrios diferentes usando la vista temporal
count_barrios = spark.sql("""
    SELECT COUNT(DISTINCT DESC_BARRIO) AS num_barrios
    FROM padron
""")

# Mostrar el resultado
count_barrios.show()
```

► (3) Spark Jobs

```
► count_barrios: pyspark.sql.dataframe.DataFrame = [num_barrios: long]
+-----+
|num_barrios|
+-----+
|          131|
+-----+
```

- 6.5) Crea una nueva columna que muestre la longitud de los campos de la columna DESC\_DISTRITO y que se llame "longitud".  
withColumnn, se usa para añadir una nueva columna o para reemplazar una columna existente con una nueva versión.

```
%python
from pyspark.sql.functions import length

# Crear una nueva columna 'longitud' que muestra la longitud de los valores en 'DESC_DISTRITO'
df = df.withColumn("longitud", length(col("DESC_DISTRITO")))

# Mostrar el esquema actualizado y algunas filas para verificar el resultado
df.printSchema()
df.show(10)
```

► (1) Spark Jobs

```
► df: pyspark.sql.dataframe.DataFrame = [COD_DISTRITO: string, DESC_DISTRITO: string ... 14 more fields]
```

|   | 2  | ARGANZUELA           | 202        | ACACIAS       | 2  | 2094  | 94 | 47 | 6  | 16 |
|---|----|----------------------|------------|---------------|----|-------|----|----|----|----|
| 0 | 0  | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01    | 10 |       |    |    |    |    |
| 1 | 18 | VILLA DE VALLECAS    | 1802       | SANTA EUGENIA | 2  | 18029 | 29 | 77 | 7  | 3  |
| 0 | 2  | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01    | 17 |       |    |    |    |    |
| 1 | 2  | ARGANZUELA           | 205        | DELICIAS      | 5  | 2062  | 62 | 71 | 6  | 6  |
| 0 | 2  | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01    | 10 |       |    |    |    |    |
| 1 | 9  | MONCLOA-ARAVACA      | 907        | ARAVACA       | 7  | 9083  | 83 | 55 | 15 | 14 |
| 0 | 0  | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01    | 15 |       |    |    |    |    |
| 1 | 3  | RETIRO               | 306        | NIÑO JESUS    | 6  | 3080  | 80 | 60 | 7  | 8  |

- 6.6) Crea una nueva columna que muestre el valor 5 para cada uno de los registros de la tabla.

```
%python
from pyspark.sql.functions import lit

# Crear una nueva columna 'longitud' que muestra la longitud de los valores en 'DESC_DISTRITO'
df = df.withColumn("valor_fijo", lit(5))

# Mostrar el esquema actualizado y algunas filas para verificar el resultado
df.printSchema()
df.show(10)
```

► (1) Spark Jobs

```
► df: pyspark.sql.dataframe.DataFrame = [COD_DISTRITO: string, DESC_DISTRITO: string ... 15 more fields]
```

|   | 2  | ARGANZUELA           | 202        | ACACIAS       | 2  | 2094  | 94  | 47  | 6  | 16 |
|---|----|----------------------|------------|---------------|----|-------|-----|-----|----|----|
| 0 | 0  | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01    | 10 | 5     |     |     |    |    |
| 1 | 18 | VILLA DE VALLECAS    | 1802       | SANTA EUGENIA | 2  | 18029 | 29  | 77  | 7  | 3  |
| 0 | 2  | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01    | 17 | 5     |     |     |    |    |
| 1 | 2  | ARGANZUELA           | 205        | DELICIAS      | 5  | 2062  | 62  | 71  | 6  | 6  |
| 0 | 2  | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01    | 10 | 5     |     |     |    |    |
| 1 | 9  | MONCLOA-ARAVACA      | 907        | ARAVACA       | 7  | 9083  | 83  | 55  | 15 | 14 |
| 0 | 0  | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01    | 15 | 5     |     |     |    |    |
| 1 | 3  | RETIRO               | 306        | NIÑO JESUS    | 6  | 3080  | 80  | 60  | 7  | 8  |
| 1 | 1  | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01    | 6  | 5     |     |     |    |    |
| 1 | 4  | SALAMANCA            | 405        | LISTA         | 5  | 4182  | 102 | 78  | 1  | 6  |
| 0 | 0  | 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01    | 9  | 5     |     |     |    |    |
| 1 | 20 | SAN BLAS-CANILLEJAS  | 2001       | SIPANCAS      | 1  | 20009 | 9   | 100 | 0  | 1  |

## • 6.7) Borra esta columna.

```
%python
df = df.drop("valor_fijo")
df.printSchema()
```

```
▶ df: pyspark.sql.dataframe.DataFrame = [COD_DISTRITO
root
|-- COD_DISTRITO: string (nullable = true)
|-- DESC_DISTRITO: string (nullable = true)
|-- COD_DIST_BARRIO: string (nullable = true)
|-- DESC_BARRIO: string (nullable = true)
|-- COD_BARRIO: string (nullable = true)
|-- COD_DIST_SECCION: string (nullable = true)
|-- COD_SECCION: string (nullable = true)
|-- COD_EDAD_INT: string (nullable = true)
|-- ESPANOLESHOMBRES: string (nullable = true)
|-- ESPANOLESMUJERES: string (nullable = true)
|-- EXTRANJEROSHOMBRES: string (nullable = true)
|-- EXTRANJEROSMUJERES: string (nullable = true)
|-- FX_CARGA: string (nullable = true)
|-- FX_DATOS_INI: string (nullable = true)
|-- FX_DATOS_FIN: string (nullable = true)
|-- longitud: integer (nullable = true)
```

## • 6.8) Particiona el DataFrame por las variables DESC\_DISTRITO y DESC\_BARRIO.

```
%python
# Guardar el DataFrame particionado en Parquet
output_path = "/FileStore/tables/Formacion_Binaia/Practica_Padron/"

df.write.partitionBy("DESC_DISTRITO", "DESC_BARRIO") \
    .format("parquet") \
    .mode("overwrite") \
    .save(output_path)
```

|                                 |                                 |
|---------------------------------|---------------------------------|
| DESC_DISTRITO=__HIVE_DEFAULT... | DESC_BARRIO=__HIVE_DEFAULT_P... |
| DESC_DISTRITO=ARGANZUELA        | DESC_BARRIO=ACACIAS             |
| DESC_DISTRITO=BARAJAS           | DESC_BARRIO=ATOCHA              |
| DESC_DISTRITO=CARABANCHEZ       | DESC_BARRIO=CHOPERA             |
| DESC_DISTRITO=CENTRO            | DESC_BARRIO=DELICIAS            |
| DESC_DISTRITO=CHAMARTIN         | DESC_BARRIO=IMPERIAL            |
| DESC_DISTRITO=CHAMBERI          | DESC_BARRIO=LEGAZPI             |
| DESC_DISTRITO=CIUDAD LINEA...   | DESC_BARRIO=PALOS DE LA FRO...  |
| DESC_DISTRITO=FUENCARRAL-...    |                                 |
| DESC_DISTRITO=HORTALEZA         |                                 |
| DESC_DISTRITO=LATINA            |                                 |
| DESC_DISTRITO=MONCLOA-A...      |                                 |
| DESC_DISTRITO=MORATALAZ         |                                 |
| DESC_DISTRITO=PUENTE DE V...    |                                 |
| DESC_DISTRITO=RETIRO            |                                 |
| DESC_DISTRITO=SALAMANCA         |                                 |
| DESC_DISTRITO=SAN BLAS-CA...    |                                 |
| DESC_DISTRITO=TETUAN            |                                 |
| DESC_DISTRITO=USERA             |                                 |
| DESC_DISTRITO=VICALVARO         |                                 |
| DESC_DISTRITO=VILLA DE VALL...  |                                 |
| DESC_DISTRITO=VILLVERDE         |                                 |

Se puede ver que ha ido bien, ya que tenemos, los distritos, y dentro de cada uno de ellos, tenemos los barrios dentro de cada distrito.

• **6.9) Almacénalo en caché. Consulta en el puerto 4040 (UI de Spark) de tu usuario local el estado de los rdds almacenados.**

```
%python
from pyspark.sql import SparkSession
df.cache()
df.show()
```

(1) Spark Jobs

|   |   |                        |            |                      |    |      |     |    |   |   |  |
|---|---|------------------------|------------|----------------------|----|------|-----|----|---|---|--|
| 0 |   | 0 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01           | 9  |      |     |    |   |   |  |
|   | 2 | ARGANZUELA             | 205        | DELICIAS             | 5  | 2113 | 113 | 74 | 0 | 2 |  |
| 0 |   | 0 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01           | 10 |      |     |    |   |   |  |
|   | 2 | ARGANZUELA             | 206        | PALOS DE LA FRONTERA | 6  | 2068 | 68  | 48 | 4 | 5 |  |
| 0 |   | 1 2024-07-07 00:00:... | 2024-07-01 | 2024-07-01           | 10 |      |     |    |   |   |  |

Como estoy trabajando en databricks, no puedo porque el puerto 4040 es local al entorno del cluster de Spark y no está disponible para acceso remoto o desde el navegador local. En Databricks, la administración de Spark y la visualización de trabajos se realiza a través de la interfaz proporcionada por Databricks, no mediante acceso local a puertos.

Podemos visualizar el job de la cache:

Details for Stage 37 (Attempt 0)

Resource Profile Id: 0

Total Time Across All Tasks: 3 s

Locality Level Summary: Process local: 1

Associated Job Ids: 31

► DAG Visualization

► Show Additional Metrics

► Event Timeline

Summary Metrics for 1 Completed Tasks

| Metric   | Min    | 25th percentile | Median | 75th percentile | Max    |
|----------|--------|-----------------|--------|-----------------|--------|
| Duration | 3 s    | 3 s             | 3 s    | 3 s             | 3 s    |
| GC Time  | 0.0 ms | 0.0 ms          | 0.0 ms | 0.0 ms          | 0.0 ms |

► Aggregated Metrics by Executor

Tasks (1)

Show 20 entries

Search:

| Index | Task ID | Attempt | Status  | Locality level | Executor ID | Host                                         | Logs | Launch Time         | Duration | GC Time | Errors |
|-------|---------|---------|---------|----------------|-------------|----------------------------------------------|------|---------------------|----------|---------|--------|
| 0     | 101     | 0       | SUCCESS | PROCESS_LOCAL  | driver      | ip-10-172-236-246.us-west-2.compute.internal |      | 2024-08-01 10:14:18 | 3 s      |         |        |

Showing 1 to 1 of 1 entries

Previous

Next

• **6.10) Lanza una consulta contra el DF resultante en la que muestre el número total de "espanoleshombres", "espanolesmujeres", extranjeroshombres" y "extranjerasmujeres" para cada barrio de cada distrito. Las columnas distrito y barrio deben ser las primeras en aparecer en el show. Los resultados deben estar ordenados en orden de más a menos según la columna "extranjerasmujeres" y desempatarán por la columna "extranjeroshombres".**

```
%python
# Convertir las columnas numéricas a int
df = df.withColumn("ESPAÑOLESOMBRES", col("ESPAÑOLESOMBRES").cast("int"))
df = df.withColumn("ESPAÑOLESMUJERES", col("ESPAÑOLESMUJERES").cast("int"))
df = df.withColumn("EXTRANJEROSHOMBRES", col("EXTRANJEROSHOMBRES").cast("int"))
df = df.withColumn("EXTRANJEROSMUJERES", col("EXTRANJEROSMUJERES").cast("int"))

df.printSchema()
```

(1) Spark Jobs

► df: pyspark.sql.dataframe.DataFrame = [COD\_DISTrito: string, DESC\_DISTrito: string ... 14 more fie

only showing top 20 rows

root

-- COD\_DISTrito: string (nullable = true)

-- DESC\_DISTrito: string (nullable = true)

-- COD\_DIST\_BARRIO: string (nullable = true)

-- DESC\_BARRIO: string (nullable = true)

-- COD\_BARRIO: string (nullable = true)

-- COD\_DIST\_SECCION: string (nullable = true)

-- COD\_SECCION: string (nullable = true)

-- COD\_EDAD\_INT: string (nullable = true)

-- ESPAÑOLESOMBRES: integer (nullable = true)

-- ESPAÑOLESMUJERES: integer (nullable = true)

-- EXTRANJEROSHOMBRES: integer (nullable = true)

-- EXTRANJEROSMUJERES: integer (nullable = true)

-- FX\_CARGA: string (nullable = true)

-- FX\_DATOS\_INI: string (nullable = true)

-- FX\_DATOS\_FIN: string (nullable = true)

-- longitud: integer (nullable = true)

Como lo tenia como String las columnas, he hecho un cast para que pueda usarlas como es adecuado.



Ejecuto la consulta y vemos los resultados

```
%python
from pyspark.sql.functions import sum, col
# Agrupar por DESC_DISTRITO y DESC_BARRIO, sumar las columnas relevantes
result_df = df.groupBy("DESC_DISTRITO", "DESC_BARRIO").agg(
    sum("ESPAÑOLESHOMBRES").alias("Total_EspanolesHombres"),
    sum("ESPAÑOLESMUJERES").alias("Total_EspanolesMujeres"),
    sum("EXTRANJEROSHOMBRES").alias("Total_ExtranjerosHombres"),
    sum("EXTRANJEROSMUJERES").alias("Total_ExtranjerosMujeres")
)

# Ordenar los resultados por Total_ExtranjerosMujeres y Total_ExtranjerosHombres
result_df = result_df.orderBy(col("Total_ExtranjerosMujeres").desc(), col("Total_ExtranjerosHombres").desc())

# Mostrar los resultados
result_df.show()
```

▶ (2) Spark Jobs

▶ result\_df: pyspark.sql.dataframe.DataFrame = [DESC\_DISTRITO: string, DESC\_BARRIO: string ... 4 more fields]

| DESC_DISTRITO       | DESC_BARRIO          | Total_EspanolesHombres | Total_EspanolesMujeres | Total_ExtranjerosHombres | Total_ExtranjerosMujeres |
|---------------------|----------------------|------------------------|------------------------|--------------------------|--------------------------|
| PUENTE DE VALLECAS  | SAN DIEGO            | 14886                  | 16515                  | 9795                     | 9759                     |
| CIUDAD LINEAL       | PUEBLO NUEVO         | 23698                  | 27603                  | 7666                     | 8301                     |
| LATINA              | ALUCHE               | 24896                  | 29873                  | 7315                     | 8123                     |
| CARABANCHEL         | VISTA ALEGRE         | 16076                  | 19626                  | 7580                     | 7988                     |
| PUENTE DE VALLECAS  | NUMANCIA             | 17256                  | 19428                  | 7772                     | 7715                     |
| VILLAVERDE          | VILLAVERDE ALTO C.H. | 17489                  | 19502                  | 7354                     | 7379                     |
| CENTRO              | EMBAJADORES          | 16514                  | 16102                  | 9510                     | 7121                     |
| CIUDAD LINEAL       | VENTAS               | 18949                  | 22299                  | 5552                     | 6381                     |
| CARABANCHEL         | PUERTA BONITA        | 12745                  | 14589                  | 6129                     | 6375                     |
| LATINA              | PUERTA DEL ANGEL     | 15941                  | 18308                  | 5666                     | 6188                     |
| FUENCARRAL-EL PARDO | VALVERDE             | 27266                  | 29556                  | 5277                     | 5903                     |
| CARABANCHEL         | SAN ISIDRO           | 14750                  | 16721                  | 5709                     | 5848                     |
| HORTALEZA           | VALDEFUENTES         | 32214                  | 32976                  | 4491                     | 5329                     |
| CARABANCHEL         | OPAÑEL               | 11876                  | 14224                  | 4915                     | 5257                     |
| VILLAVERDE          | LOS ROSALES          | 14267                  | 15765                  | 5112                     | 5223                     |
| VILLA DE VALLECAS   | ENSANCHE DE VALLECAS | 23888                  | 24623                  | 4167                     | 5061                     |
| CENTRO              | UNIVERSIDAD          | 12256                  | 12210                  | 4707                     | 5060                     |

## • 6.11) Elimina el registro en caché.

```
%python
df.unpersist()
```

Out[36]: DataFrame[COD\_DISTRITO: string, DESC\_DISTRITO: string, COD\_DIST\_BARRIO: string, DESC\_BARRIO: string, COD\_BARRIO: string, COD\_DIST\_SECCION: string, COD\_SECCION: string, COD\_EDAD\_INT: string, ESPAÑOLESHOMBRES: int, ESPAÑOLESMUJERES: int, EXTRANJEROSHOMBRES: int, EXTRANJEROSMUJERES: int, FX\_CARGA: string, FX\_DATOS\_INI: string, FX\_DATOS\_FIN: string, longitud: int]

## • 6.12) Crea un nuevo DataFrame a partir del original que muestre únicamente una columna con DESC\_BARRIO, otra con DESC\_DISTRITO y otra con el número total de "espanoleshombres" residentes en cada distrito de cada barrio. Únelo (con un join) con el DataFrame original a través de las columnas en común.

```
%python
from pyspark.sql.functions import col, sum
# Suponiendo que 'df' es tu DataFrame original
# Agrupar por DESC_BARRIO y DESC_DISTRITO, sumar ESPAÑOLESHOMBRES
df_sum = df.groupBy("DESC_BARRIO", "DESC_DISTRITO").agg(
    sum(col("ESPAÑOLESHOMBRES")).alias("Total_EspanolesHombres")
)

# Mostrar el esquema y las primeras filas para confirmar
df_sum.printSchema()
df_sum.show(10)
```

▶ (2) Spark Jobs

▶ df\_sum: pyspark.sql.dataframe.DataFrame = [DESC\_BARRIO: string, DESC\_D

```
root
|-- DESC_BARRIO: string (nullable = true)
|-- DESC_DISTRITO: string (nullable = true)
|-- Total_EspanolesHombres: long (nullable = true)
```

| DESC_BARRIO       | DESC_DISTRITO       | Total_EspanolesHombres |
|-------------------|---------------------|------------------------|
| ACACIAS           | ARGANZUELA          | 15297                  |
| VALVERDE          | FUENCARRAL-EL PARDO | 27266                  |
| FUENTELARREINA    | FUENCARRAL-EL PARDO | 1533                   |
| PAVONES           | MORATALAZ           | 3572                   |
| EL GOLOSO         | FUENCARRAL-EL PARDO | 9101                   |
| SAN JUAN BAUTISTA | CIUDAD LINEAL       | 5452                   |
| CANILLAS          | HORTALEZA           | 16510                  |
| PROSPERIDAD       | CHAMARTIN           | 14458                  |
| LEGAZPI           | ARGANZUELA          | 8956                   |
| COSTILLARES       | CIUDAD LINEAL       | 9871                   |

only showing top 10 rows

- ▶ (4) Spark Jobs

```
df_joined: pyspark.sql.dataframe.DataFrame = [DESC_BARRIO: string, DESC_DISTRITO: string ... 15 more fields]
```

[illegible]

- **6.13) Repite la función anterior utilizando funciones de ventana. (over(Window.partitionBy.....)).**

## Ventanas (Window)

- Propósito: Permiten realizar cálculos avanzados como agregados y rankings dentro de subconjuntos de datos.
- Uso: Definidas con `Window` y aplicadas usando funciones como `SUM()` o `ROW_NUMBER()`.
- Ejemplo: Calcular una suma acumulativa dentro de cada grupo.

## Particiones (`partitionBy`)

- Propósito: Organizan datos en disco para mejorar la eficiencia de lectura y escritura.
- Uso: Definidas al escribir datos usando `partitionBy`, dividiendo los datos en subdirectorios.
- Ejemplo: Almacenar datos en diferentes carpetas basadas en valores de columnas.

Diferencia Clave:

- Ventanas: Para cálculos analíticos dentro de datos.
- Particiones: Para organizar datos en almacenamiento distribuido.

- ▶ (3) Spark Jobs

```
df_with_sum: pyspark.sql.dataframe.DataFrame = [COD_DISTRITO: string, DESC_DISTRITO: string ... 15 more fields]
```

[illegible]

- ▶ (4) Spark Jobs

```
df_joined: pyspark.sql.dataframe.DataFrame = [DESC_BARRIO: string, DESC_DISTRITO: string ... 15 more fields]
```

[illegible]

only showing top 10 rows

```
%python
from pyspark.sql.functions import col, sum

# Filtrar los datos para los distritos específicos
# isin() se utiliza para verificar si los valores en una columna de un DataFrame coinciden con cualquiera de los valores proporcionados en una lista dada. Si un valor en la columna del DataFrame se encuentra en la lista, devuelve verdadero; de lo contrario, devuelve falso. Esta función es útil para filtrar datos basados en valores específicos en los que estás interesado.
df_filtered = df.filter(col("DESC_DISTrito").isin("CENTRO", "BARAJAS", "RETIRO"))

# Crear la tabla de contingencia (pivot table)
pivot_df = df_filtered.groupBy("COD_EDAD_INT").pivot("DESC_DISTrito").agg(
    sum("ESPAÑOLSHUJERES").alias("Total_EspanolesHujeres")
)

pivot_df.show()
```

- ▶ (7) Spark Jobs

```
df_filtered: pyspark.sql.dataframe.DataFrame = [COD_DISTRITO: string, DESC_DISTRITO: string ... 13 more fields]
```

```

pivot df: pyspark.sql.dataframe.DataFrame = [COD_EDAD INT: string, BARAJAS: long ... 2 more fields]

```

|  | COD_EDAD_INT | BARAJAS | CENTRO | RETIRO |
|--|--------------|---------|--------|--------|
|  | 51           | 449     | 803    | 805    |
|  | 7            | 221     | 213    | 416    |
|  | 15           | 271     | 255    | 445    |
|  | 54           | 372     | 766    | 775    |
|  | 11           | 242     | 249    | 435    |
|  | 69           | 219     | 579    | 854    |
|  | 29           | 170     | 848    | 606    |
|  | 42           | 323     | 768    | 731    |
|  | 87           | 105     | 265    | 455    |
|  | 73           | 260     | 492    | 767    |
|  | 64           | 255     | 735    | 838    |
|  | 3            | 151     | 181    | 314    |
|  | 30           | 194     | 849    | 601    |
|  | 34           | 205     | 837    | 602    |
|  | 59           | 362     | 791    | 821    |
|  | 8            | 239     | 219    | 381    |

- 6.15) Utilizando este nuevo DF, crea 3 columnas nuevas que hagan referencia a qué porcentaje de la suma de "espanolesmujeres" en los tres distritos para cada rango de edad representa cada uno de los tres distritos. Debe estar redondeada a 2 decimales. Puedes imponerte la condición extra de no apoyarte en ninguna columna auxiliar creada para el caso.

```
%python
from pyspark.sql.functions import col, round

# Calcular la suma total de ESPANOLESMUJERES para cada rango de edad
pivot_df = pivot_df.withColumn("Total_Sum", col("CENTRO") + col("BARAJAS") + col("RETIRO"))

# Calcular los porcentajes de cada distrito respecto al total y redondear a 2 decimales
pivot_df = pivot_df.withColumn("Centro_Percentage", round((col("CENTRO") / col("Total_Sum")) * 100, 2))
pivot_df = pivot_df.withColumn("Barajas_Percentage", round((col("BARAJAS") / col("Total_Sum")) * 100, 2))
pivot_df = pivot_df.withColumn("Retiro_Percentage", round((col("RETIRO") / col("Total_Sum")) * 100, 2))

# Mostrar el resultado
pivot_df.show()
```

▶ (3) Spark Jobs

▶ pivot\_df: pyspark.sql.dataframe.DataFrame = [COD\_EDAD\_INT: string, BARAJAS: long ... 6 more fields]

|  | COD_EDAD_INT | BARAJAS | CENTRO | RETIRO | Total_Sum | Centro_Percentage | Barajas_Percentage | Retiro_Percentage |
|--|--------------|---------|--------|--------|-----------|-------------------|--------------------|-------------------|
|  | 51           | 449     | 803    | 805    | 2057      | 39.04             | 21.83              | 39.13             |
|  | 7            | 221     | 213    | 416    | 850       | 25.06             | 26.0               | 48.94             |
|  | 15           | 271     | 255    | 445    | 971       | 26.26             | 27.91              | 45.83             |
|  | 54           | 372     | 766    | 775    | 1913      | 40.04             | 19.45              | 40.51             |
|  | 11           | 242     | 249    | 435    | 926       | 26.89             | 26.13              | 46.98             |
|  | 69           | 219     | 579    | 854    | 1652      | 35.05             | 13.26              | 51.69             |
|  | 29           | 170     | 848    | 606    | 1624      | 52.22             | 10.47              | 37.32             |
|  | 42           | 323     | 768    | 731    | 1822      | 42.15             | 17.73              | 40.12             |
|  | 87           | 105     | 265    | 455    | 825       | 32.12             | 12.73              | 55.15             |
|  | 73           | 260     | 492    | 767    | 1519      | 32.39             | 17.12              | 50.49             |
|  | 64           | 255     | 735    | 838    | 1828      | 40.21             | 13.95              | 45.84             |
|  | 3            | 151     | 181    | 314    | 646       | 28.02             | 23.37              | 48.61             |
|  | 30           | 194     | 849    | 601    | 1644      | 51.64             | 11.8               | 36.56             |
|  | 34           | 205     | 837    | 602    | 1644      | 50.91             | 12.47              | 36.62             |
|  | 59           | 362     | 791    | 821    | 1974      | 40.07             | 18.34              | 41.59             |
|  | 8            | 239     | 219    | 381    | 839       | 26.1              | 28.49              | 45.41             |

- **6.16) Guarda el archivo csv original particionado por distrito y por barrio (en ese orden) en un directorio local. Consulta el directorio para ver la estructura de los ficheros y comprueba que es la esperada.**

Cada distrito, tendrá sus barrios.

```
%python
# Guardar el DataFrame particionado por DESC_DISTRITO y DESC_BARRIO en un directorio local
df.write.partitionBy("DESC_DISTRITO", "DESC_BARRIO").csv("/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16", header=True)
```

```
%python
# Listar los archivos en el directorio local para verificar la estructura
display(dbutils.fs.ls("/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16"))
```

▶ (3) Spark Jobs

Table ▾ +

🔍 🔍

|    | path                                                                                               |
|----|----------------------------------------------------------------------------------------------------|
| 1  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=ARGANZUELA/          |
| 2  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=BARAJAS/             |
| 3  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=CARABANCHEL/         |
| 4  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=CENTRO/              |
| 5  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=CHAMARTIN/           |
| 6  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=CHAMBERI/            |
| 7  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=CIUDAD LINEAL/       |
| 8  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=FUENCARRAL-EL PARDO/ |
| 9  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=HORTALEZA/           |
| 10 | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=LATINA/              |
| 11 | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=MONCLOA-ARAVACA/     |
| 12 | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=MORATALAZ/           |
| 13 | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=PUENTE DE VALLECAS/  |
| 14 | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/DESC_DISTRITO=RETIRO/              |

Da como esperaba.

- **6.17) Haz el mismo guardado pero en formato parquet. Compara el peso del archivo con el resultado anterior.**

```
%python
# Guardar el DataFrame particionado por DESC_DISTRITO y DESC_BARRIO en un directorio local en formato Parquet
df.write.partitionBy("DESC_DISTRITO", "DESC_BARRIO").parquet("/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet", mode='overwrite')
```

```
%python
# Listar los archivos en el directorio local para verificar la estructura
display(dbutils.fs.ls("/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet"))
```

▶ (3) Spark Jobs

Table ▾ +

|    | path                                                                                                       | name                               | size |
|----|------------------------------------------------------------------------------------------------------------|------------------------------------|------|
| 1  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=ARGANZUELA/          | DESC_DISTRITO=ARGANZUELA/          | 0    |
| 2  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=BARAJAS/             | DESC_DISTRITO=BARAJAS/             | 0    |
| 3  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=CARABANCHEL/         | DESC_DISTRITO=CARABANCHEL/         | 0    |
| 4  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=CENTRO/              | DESC_DISTRITO=CENTRO/              | 0    |
| 5  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=CHAMARTIN/           | DESC_DISTRITO=CHAMARTIN/           | 0    |
| 6  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=CHAMBERI/            | DESC_DISTRITO=CHAMBERI/            | 0    |
| 7  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=CIUDAD LINEAL/       | DESC_DISTRITO=CIUDAD LINEAL/       | 0    |
| 8  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=FUENCARRAL-EL PARDO/ | DESC_DISTRITO=FUENCARRAL-EL PARDO/ | 0    |
| 9  | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=HORTALEZA/           | DESC_DISTRITO=HORTALEZA/           | 0    |
| 10 | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=LATINA/              | DESC_DISTRITO=LATINA/              | 0    |
| 11 | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=MONCLOA-ARAVACA/     | DESC_DISTRITO=MONCLOA-ARAVACA/     | 0    |
| 12 | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=MORATALAZ/           | DESC_DISTRITO=MORATALAZ/           | 0    |
| 13 | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=PUENTE DE VALLECAS/  | DESC_DISTRITO=PUENTE DE VALLECAS/  | 0    |
| 14 | dbfs:/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/DESC_DISTRITO=RETIRO/              | DESC_DISTRITO=RETIRO/              | 0    |

Ahora compararemos los pesos de los archivos.

```
%python
# Listar los archivos y subdirectorios en el directorio CSV
csv_dir = "/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16/"
csv_files = dbutils.fs.ls(csv_dir)

# Función para calcular el tamaño total de los archivos en un directorio, incluyendo subdirectorios
def calculate_size(dir_path):
    files = dbutils.fs.ls(dir_path)
    total_size = 0
    for file in files:
        if file.isDir():
            total_size += calculate_size(file.path)
        else:
            total_size += file.size
    return total_size

# Calcular el tamaño total de los archivos CSV
csv_total_size = calculate_size(csv_dir)
print(f"Tamaño total de los archivos CSV: {csv_total_size} bytes")
```

Tamaño total de los archivos CSV: 19014515 bytes

```
%python
parquet_dir = "/FileStore/tables/Formacion_Binaia/Practica_Padron/Ej_6_16_parquet/"
parquet_files = dbutils.fs.ls(parquet_dir)

# Calcular el tamaño total de los archivos Parquet
parquet_total_size = calculate_size(parquet_dir)
print(f"Tamaño total de los archivos Parquet: {parquet_total_size} bytes")
```

Tamaño total de los archivos Parquet: 6463347 bytes

Se puede ver que en parquet, nos ahorramos casi 13 millones de bytes, por lo que es mucho más eficiente, gasta mucha menos memoria y es mucho más rápido para trabajar.

Por otra parte, el código para CSV es más largo porque la estructura de archivos CSV generada por Spark incluye múltiples subdirectorios y archivos para cada partición, requiriendo un recorrido recursivo para calcular su tamaño. En cambio, los archivos Parquet tienen una estructura más compacta y eficiente, lo que simplifica tanto el almacenamiento como el cálculo de su tamaño.

## 7- ¿Y si juntamos Spark y Hive?

- 7.1) Por último, prueba a hacer los ejercicios sugeridos en la parte de Hive con el csv "Datos Padrón" (incluyendo la importación con Regex) utilizando desde Spark EXCLUSIVAMENTE sentencias spark.sql, es decir, importar los archivos desde local directamente como tablas de Hive y haciendo todas las consultas sobre estas tablas sin transformarlas en ningún momento en DataFrames ni DataSets

Creo sesión spark:

```
▶ ✓ 11:40 AM (2s)

%python
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, trim, when

spark = SparkSession.builder.appName("Spark y Hive").getOrCreate()
```

Creo la tabla sin corregirla:

```
%python
# Crear la base de datos si no existe
spark.sql("CREATE DATABASE IF NOT EXISTS datos_padron")

# Usar la base de datos
spark.sql("USE datos_padron")

# Crear la tabla padron_txt con formato delimitado
spark.sql("""
    CREATE TABLE IF NOT EXISTS padron_txt (
        COD_DISTrito INT,
        DESC_DISTrito STRING,
        COD_DIST_BARRIO INT,
        DESC_BARRIO STRING,
        COD_BARRIO INT,
        COD_DIST_SECCION INT,
        COD_SECCION INT,
        COD_EDAD_INT STRING,
        ESPANOLESHOMBRES INT,
        ESPANOLESMUJERES INT,
        EXTRANJEROSHOMBRES INT,
        EXTRANJEROSMUJERES INT,
        FX_CARGA STRING,
        FX_DATOS_INI STRING,
        FX_DATOS_FIN STRING
    )
    ROW FORMAT DELIMITED
    FIELDS TERMINATED BY ';'
    LINES TERMINATED BY '\n'
    STORED AS TEXTFILE
    TBLPROPERTIES ("skip.header.line.count"="1");
""")
```

Inserto los datos en la tabla, copiando el csv en otra ubicación, porque si ejerzo el comando de "LOAD DATA", se elimina de la ubicación local:

```
%python
dbutils.fs.cp('/FileStore/tables/Formacion_Binaia/Practica_Padron/padron_estadistica.csv', '/FileStore/tables/Formacion_Binaia/Practica_Padron/padron.csv')
spark.sql("""
    LOAD DATA INPATH '/FileStore/tables/Formacion_Binaia/Practica_Padron/padron.csv'
    INTO TABLE padron_txt
""")
```

Hago la comprobación de que todo ha salido bien:

```
%python
spark.sql("SELECT * FROM padron_text LIMIT 5").show()

+ (1) Spark Jobs

-----
[COD_DISTRITO]      DESC_DISTRITO|COD_DIST_BARRIO      DESC_BARRIO|COD_BARRIO|COD_DIST_SECCION|COD_SECCION|COD_EDAO_INT|ESPAÑOLESHOMBRES|ESPAÑOLESMUJERES|EXTRANJEROSHOMBRES|EXTRANJERMUJERES|FX_CARGA|FX_DATOS_INI|FX_DATA
OD_FIN]
-----
mu11|      DESC_DISTRITO|      mu11|      DESC_BARRIO|      mu11|      mu11|      mu11|COD_EDAO_INT|      mu11|      mu11|      mu11|      FX_CARGA|FX_DATOS_INI|FX_DATA
OD_FIN]
2|"ARGANZUELA ...|      282|"ACACIAS ...|      2|      2094|      94|"      47"|      6|      16|      0|      0|"2024-07-07 00:00..."|"2024-07-01"|"2024-
07-01"
18|"VELLA DE VALLECA...|      1802|"SANTA EUGENIA ...|      2|      18029|      29|"      77"|      7|      3|      0|      2|"2024-07-07 00:00..."|"2024-07-01"|"2024-
07-01"
2|"ARGANZUELA ...|      205|"DELICIAS ...|      5|      2002|      62|"      71"|      6|      6|      0|      2|"2024-07-07 00:00..."|"2024-07-01"|"2024-
07-01"
9|"MONCLOA-ARAVACA ...|      907|"ARAVACA ...|      7|      9083|      83|"      55"|      15|      14|      0|      0|"2024-07-07 00:00..."|"2024-07-01"|"2024-
```



Ahora creo la tabla padron\_txt\_2 mediante CTAS, para crear una tabla sin espacios en blanco y sin comillas dobles:

```
%python
from pyspark.sql.functions import trim, regexp_replace, col

spark.sql("""
CREATE TABLE IF NOT EXISTS padron_txt_2 AS
SELECT
    CAST(trim(regexp_replace(COD_DISTrito, '"', '')) AS INT) AS COD_DISTrito,
    trim(regexp_replace(DESC_DISTrito, '"', '')) AS DESC_DISTrito,
    CAST(trim(regexp_replace(COD_DIST_BARRIO, '"', '')) AS INT) AS COD_DIST_BARRIO,
    trim(regexp_replace(DESC_BARRIO, '"', '')) AS DESC_BARRIO,
    CAST(trim(regexp_replace(COD_BARRIO, '"', '')) AS INT) AS COD_BARRIO,
    CAST(trim(regexp_replace(COD_DIST_SECCION, '"', '')) AS INT) AS COD_DIST_SECCION,
    CAST(trim(regexp_replace(COD_SECCION, '"', '')) AS INT) AS COD_SECCION,
    trim(regexp_replace(COD_EDAD_INT, '"', '')) AS COD_EDAD_INT,
    CAST(trim(regexp_replace(ESPAÑOLES_HOMBRES, '"', '')) AS INT) AS ESPAÑOLES_HOMBRES,
    CAST(trim(regexp_replace(ESPAÑOLES_MUJERES, '"', '')) AS INT) AS ESPAÑOLES_MUJERES,
    CAST(trim(regexp_replace(EXTRANJEROS_HOMBRES, '"', '')) AS INT) AS EXTRANJEROS_HOMBRES,
    CAST(trim(regexp_replace(EXTRANJEROS_MUJERES, '"', '')) AS INT) AS EXTRANJEROS_MUJERES,
    trim(regexp_replace(FX_CARGA, '"', '')) AS FX_CARGA,
    trim(regexp_replace(FX_DATOS_INI, '"', '')) AS FX_DATOS_INI,
    trim(regexp_replace(FX_DATOS_FIN, '"', '')) AS FX_DATOS_FIN
FROM padron_txt;
""")
```

Hago de nuevo comprobación y veo que ha ido bien:

```
spark.sql("SELECT * FROM padron_txt_2 LIMIT 5").show()
```

▶ (2) Spark Jobs

| [COD_DISTrito] | DESC_DISTrito | [COD_DIST_BARRIO] | DESC_BARRIO | [COD_BARRIO]  | [COD_DIST_SECCION] | [COD_SECCION] | [COD_EDAD_INT] | ESPAÑOLES_HOMBRES | ESPAÑOLES_MUJERES | EXTRANJEROS_HOMBRES | EXTRANJEROS_MUJERES | FX_CARGA | FX_DATOS_INI         | FX_DATOS_FIN          |
|----------------|---------------|-------------------|-------------|---------------|--------------------|---------------|----------------|-------------------|-------------------|---------------------|---------------------|----------|----------------------|-----------------------|
| 1              | nu11          | DESC_DISTrito     | nu11        | DESC_BARRIO   | nu11               | nu11          | [COD_EDAD_INT] | nu11              | nu11              | nu11                | nu11                | FX_CARGA | FX_DATOS_INI         | FX_DATOS_FIN          |
| 2              | 2             | ARGANZUELA        | 202         | ACACIAS       | 2                  | 2094          | 94             | 47                | 6                 | 16                  | 0                   | 0        | 2024-07-07 00:00:... | 2024-07-01 2024-07-01 |
| 3              | 18            | VILLA DE VALLECAS | 1802        | SANTA EUGENIA | 2                  | 18029         | 29             | 77                | 7                 | 3                   | 0                   | 2        | 2024-07-07 00:00:... | 2024-07-01 2024-07-01 |
| 4              | 2             | ARGANZUELA        | 205         | DELICIAS      | 5                  | 2062          | 62             | 71                | 6                 | 6                   | 0                   | 2        | 2024-07-07 00:00:... | 2024-07-01 2024-07-01 |
| 5              | 9             | MONCLOA-ARAVACA   | 907         | ARAVACA       | 7                  | 9083          | 83             | 55                | 15                | 14                  | 0                   | 0        | 2024-07-07 00:00:... | 2024-07-01 2024-07-01 |

Ahora lo hago con expresiones regulares:

```
%python
#expresiones regulares
spark.sql("""
CREATE TABLE padron_hive_regex (
    COD_DISTrito STRING,
    DESC_DISTrito STRING,
    COD_DIST_BARRIO STRING,
    DESC_BARRIO STRING,
    COD_BARRIO STRING,
    COD_DIST_SECCION STRING,
    COD_SECCION STRING,
    COD_EDAD_INT STRING,
    ESPAÑOLES_HOMBRES STRING,
    ESPAÑOLES_MUJERES STRING,
    EXTRANJEROS_HOMBRES STRING,
    EXTRANJEROS_MUJERES STRING,
    FX_CARGA STRING,
    FX_DATOS_INI STRING,
    FX_DATOS_FIN STRING
)
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.RegexSerDe'
WITH SERDEPROPERTIES (
    'input.regex' = '^(?=[0-9+]);\\"([^\"]*)\\";(?=[0-9+]);\\"([^\"]*)\\";(?=[0-9+]);(?=[0-9+]);(?=[0-9+]);\\"([^\"]*)\\";(?=[0-9+]);(?=[0-9+]);(?=[0-9+]);\\"([^\"]*)\\";(?=[0-9+]);\\"([^\"]*)\\";(?=[0-9+]);\\"([^\"]*)\\";$'
)
STORED AS TEXTFILE;
""")
```

Meto los datos:

```
01:47 PM (5s) 10

%python
dbutils.fs.cp('/FileStore/tables/Formacion_Binaia/Practica_Padron/padron_estadistica.csv', '/FileStore/tables/Formacion_Binaia/Practica_Padron/padron.csv')
spark.sql("""
    LOAD DATA INPATH '/FileStore/tables/Formacion_Binaia/Practica_Padron/padron.csv'
    INTO TABLE padron_hive_regex
""")
```

Y compruebo que ha salido bien:

Python

spark.sql("SELECT \* FROM padron\_hive\_regex LIMIT 5").show()

(1) Spark Jobs

| [COD_DISTRICTO] | DESC_DISTRICTO | [COD_DIST_BARRIO] | DESC_BARRIO | [COD_BARRIO]  | [COD_DIST_SECCION] | [COD_SECCION] | [COD_EDAD_INT] | [ESPAÑOLSHOMBRES] | [ESPAÑOLESMUJERES] | [EXTRANJEROSHOMBRES] | [EXTRANJEROSMUJERES] | FX_CARGA             | FX_DATOS_INI         | FX_DATOS_FIN |      |
|-----------------|----------------|-------------------|-------------|---------------|--------------------|---------------|----------------|-------------------|--------------------|----------------------|----------------------|----------------------|----------------------|--------------|------|
| 1               | 2              | 1802              | 202         | 2             | 2894               | 94            | 47             | 6                 | 16                 | 0                    | 0                    | 2024-07-07 00:00:... | 2024-07-01           | 2024         |      |
| 1               | 18             | VILLA DE VALLECAS | 1802        | SANTA EUGENIA | 2                  | 18029         | 29             | 77                | 7                  | 3                    | 0                    | 2                    | 2024-07-07 00:00:... | 2024-07-01   | 2024 |
| 1               | 2              | ARGANZUELA        | 205         | DELICIAS      | 5                  | 2062          | 62             | 71                | 6                  | 6                    | 0                    | 2                    | 2024-07-07 00:00:... | 2024-07-01   | 2024 |
| 1               | 9              | MONCLOA-ARAVACA   | 907         | ARAVACA       | 7                  | 9083          | 83             | 55                | 15                 | 14                   | 0                    | 0                    | 2024-07-07 00:00:... | 2024-07-01   | 2024 |